

T.C GALATASARAY ÜNİVERSİTESİ
MÜHENDİSLİK VE TEKNOLOJİ FAKÜLTESİ

ÜRETKEN YAPAY ZEKA TABANLI HABER METNİ ÖZETLEME
YAKLAŞIMLARI

(Approches de Résumé de Textes d'Actualité Basées sur l'IA Générative)

BİTİRME PROJESİ
MERT SAMET KAYACIOĞLU

Bölüm : BİLGİSAYAR MÜHENDİSLİĞİ
Danışman : Dr. Öğr. Üyesi İSMAİL BURAK PARLAK

MAYIS 2026

Préface

Ce projet de fin d'études a été réalisé afin d'étudier les performances des modèles de résumé de texte multilingues développés à l'aide des techniques de traitement automatique du langage naturel. Dans ce cadre, des modèles basés sur mBART ont été entraînés et évalués pour résumer des articles de presse dans 15 langues différentes en utilisant le jeu de données XLSum. Ce travail a été effectué dans le cadre du programme de licence en ingénierie informatique de l'Université Galatasaray et a permis d'appliquer des connaissances théoriques à un problème concret.

Le choix de ce sujet est motivé par le développement rapide des grands modèles de langage et par leur utilisation de plus en plus fréquente dans les applications destinées aux utilisateurs. Cette évolution montre une interaction de plus en plus importante avec le langage humain. Au cours de ce projet, j'ai acquis des compétences importantes en traitement des données, en entraînement de modèles, en évaluation multilingue et en analyse des résultats.

Je tiens à remercier mon encadrant, Dr. İsmail Burak Parlak, pour son accompagnement et ses précieux conseils. Je remercie également ma famille et mes amis pour leur soutien tout au long de ce projet.

J'espère que ce travail sera utile pour les lecteurs intéressés par ce domaine.

22.05.2026

Mert Samet Kayacioğlu

Table des Matières

Préface	ii
Table des Matières	iii
Liste des Notations	vi
Liste des Figures	vii
Liste des Tableaux	viii
Résumé	ix
Özet	x
1 INTRODUCTION	1
2 REVUE DE LITTERATURE	5
2.1 Résumé d’actualités et spécificités du domaine	6
2.2 Modèles transformer pour le résumé	7
2.3 Modèles multilingues et résumé multilingue	7
2.4 Évaluation automatique des résumés	8
2.5 Fidélité factuelle et hallucination dans les résumés	9
2.6 Systèmes de résumé d’actualités et intégration applicative	10
3 DEFINITION DU PROBLEME	11
4 METHODOLOGIES	14
4.1 Approche méthodologique générale	14
4.2 Familles de modèles et choix des modèles	16
4.2.1 Première chaîne d’entraînement mBART	17
4.2.2 Deuxième chaîne d’entraînement mBART	17
4.3 Méthode de génération des résumés	19
4.4 Méthode d’évaluation	19
4.4.1 Jeu de données d’évaluation et plan des modèles	19

4.4.2	Métriques classiques et comportementales	20
4.4.3	Scores proxy composites	20
4.5	Architecture de l'application web	21
4.5.1	Approche d'ingestion en arrière-plan	21
4.5.2	Couches de services	22
4.5.3	API et interface utilisateur	23
4.6	Qualité des sources et gestion des erreurs	23
5	APPLICATION NUMERIQUE	25
5.1	Jeu de données XL-Sum	25
5.1.1	Répartition linguistique	27
5.2	Modèles intégrés dans le projet	28
5.3	Architecture de l'application	31
5.3.1	Paramètres applicatifs	32
5.4	Pipeline d'évaluation	32
5.4.1	Formules des métriques classiques	33
5.4.2	Métriques source et comportement	34
5.4.3	Scores proxy composites	36
6	ANALYSE DES RESULTATS OBTENUS ET DISCUSSIONS	39
6.1	Classement global des modèles	40
6.2	Compression, complétude et abstraction	43
6.3	Analyse de la latence par langue	45
6.4	Relations entre les métriques	47
6.5	Discussion sur le choix du modèle	50
6.6	Limites de l'évaluation	51
6.7	Conclusion de l'analyse	52
7	CONCLUSIONS ET PERSPECTIVES	53
7.1	Bilan général du projet	53
7.2	Synthèse des résultats obtenus	53
7.3	Apports du travail	55

7.4	Limites du projet	56
7.5	Perspectives d'amélioration	57
7.6	Conclusion finale	58
Bibliographie		59
ANNEXES		63

Liste des Notations

API	Application Programming Interface
BART	Bidirectional and Auto-Regressive Transformers
BLEU	Bilingual Evaluation Understudy
CSV	Comma-Separated Values
CUDA	Compute Unified Device Architecture
FP16	Floating Point 16-bit
HTML	HyperText Markup Language
JSON	JavaScript Object Notation
JSONL	JSON Lines
LCS	Longest Common Subsequence
METEOR	Metric for Evaluation of Translation with Explicit ORdering
mBART	Multilingual Bidirectional and Auto-Regressive Transformer
mT5	Massively Multilingual Text-to-Text Transfer Transformer
PDF	Portable Document Format
ROUGE	Recall-Oriented Understudy for Gisting Evaluation
RSS	Really Simple Syndication
URL	Uniform Resource Locator
XLSX	Office Open XML Spreadsheet
XL-Sum	Large-scale Multilingual Abstractive Summarization

Liste des Figures

4.1	Flux méthodologique général du projet	15
4.2	Flux de collecte et de génération de résumés en arrière-plan	22
5.1	Nombre d'exemples XL-Sum par langue et par split	27
5.2	Longueur moyenne des articles et des résumés dans le split train	29
5.3	Nouveauté moyenne des bigrammes par langue et par split	30
6.1	Classement global des modèles selon les métriques principales	41
6.2	Compromis entre latence moyenne et capacité globale	43
6.3	Compromis entre taux de compression et complétude automatique	44
6.4	Latence moyenne par langue et par modèle	45
6.5	Latence moyenne normalisée par 1.000 tokens source	46
6.6	Distribution cumulative empirique de la latence	47
6.7	Corrélation entre les métriques d'évaluation	48
6.8	Taux de victoire exemple par exemple selon les métriques	49

Liste des Tableaux

4.1	Familles de modèles utilisées dans le projet	16
4.2	Principales différences entre les chaînes d’entraînement mBART	18
5.1	Langues de l’application et couverture XL-Sum dans le projet	26
5.2	Répartition globale de XL-Sum dans les sous-ensembles exécutables . . .	27
5.3	Nombre d’exemples XL-Sum par langue	28
5.4	Informations de configuration des principaux modèles	29
5.5	Comparaison des deux chaînes d’entraînement mBART	31
6.1	Synthèse macro des résultats sur XL-Sum test	40
6.2	Meilleur modèle par langue selon le score global de capacité	42
6.3	Taux de victoire exemple par exemple dans l’évaluation complète	50
6.4	Interprétation pratique des modèles	51

Résumé

L'objectif de ce projet de fin d'études est de développer un système web assisté par intelligence artificielle qui collecte automatiquement des actualités en plusieurs langues, extrait le texte principal des articles, les résume et les présente sous forme d'un flux filtrable. Le projet répond au problème de la surcharge d'information créée par le grand volume d'actualités en ligne. Il permet à l'utilisateur d'accéder rapidement à des résumés courts et vérifiables selon la langue, le sujet, la région, le pays, la source et les mots-clés choisis.

La valeur originale du projet est de réunir dans un même système la collecte d'actualités, l'extraction de texte, le contrôle de qualité, le résumé multilingue, la traduction optionnelle, le stockage en base de données et une interface web. Les articles sont collectés à partir de sources RSS, puis les textes sont nettoyés et résumés avec des modèles locaux fondés sur BART, mBART et mT5, entraînés ou affinés avec le jeu de données XL-Sum. Le système utilise aussi un planificateur en arrière-plan, une base SQLite, un mécanisme de cache et un traitement équilibré des sources. Les modèles ont été évalués avec des mesures telles que ROUGE, BLEU, METEOR-lite, la compression, la latence, la cohérence, l'exactitude, la clarté, la pertinence et l'efficacité. Le résultat obtenu est un prototype fonctionnel qui prend en charge 15 langues et présente les actualités résumées via une interface web et une API.

Les contraintes réalistes ont été prises en compte dans la conception. Les contraintes économiques sont réduites par l'utilisation de modèles locaux, ce qui limite la dépendance aux services payants. Les contraintes de durabilité sont abordées par le cache et par la réduction des traitements répétés. Les aspects éthiques, sociaux et politiques sont pris en compte en affichant les liens vers les articles originaux, en laissant le choix des sources à l'utilisateur et en appliquant un contrôle de qualité. Ce projet peut contribuer aux domaines du résumé automatique, du traitement multilingue des langues et de l'accès rapide à l'information. Il peut aussi apporter une valeur socio-économique en facilitant le suivi de l'actualité et en faisant gagner du temps aux utilisateurs.

Özet

Bu proje, güncel haber içeriklerinin çok dilli özetleme modelleriyle otomatik olarak işlenmesini, farklı model çıktılarının ölçülebilir kriterlerle değerlendirilmesini ve seçilen modellerin anlık haber akışı sağlayan bir web uygulamasına entegre edilmesini konu almaktadır. Projenin temel çıkış noktası, günümüzde haber içeriklerinin üretilmesi ve kullanıcıların farklı dillerdeki haberleri kısa, anlaşılır ve güvenilir biçimde takip etme ihtiyacının artmasıdır. Haber siteleri ve RSS akışları sürekli güncellenmekte; ancak bu akıştaki metinler çoğu zaman uzun, tekrar eden ayrıntılar içeren ve kullanıcı açısından hızlı taraya elverişli olmayan yapıdadır. Bu nedenle proje, haber metinlerinden otomatik özet üretme problemini yalnızca bir model eğitimi problemi olarak değil, uçtan uca çalışan bir haber toplama, özetleme, değerlendirme ve sunma sistemi olarak ele almıştır.

Projenin kapsamı üç ana bileşenden oluşmaktadır. İlk bileşen, haber özetleme modellerinin eğitilmesi ve kullanılabilir hale getirilmesidir. Bu kapsamda BART, mBART ve mT5 tabanlı özetleme modelleri incelenmiş; özellikle çok dilli haber özetleme görevine uygun modeller üzerinde durulmuştur. Projede İngilizce odaklı modellerin yanında Türkçe, İngilizce, Fransızca, İspanyolca, Arapça, Hintçe, Çince, Japonca, Korece, Rusça ve Vietnamca gibi farklı dillerde çalışabilen çok dilli modeller kullanılmıştır. İkinci bileşen, eğitilen veya projeye dahil edilen modellerin sistematik biçimde değerlendirilmesi ve karşılaştırılmasıdır. Bu aşamada modeller yalnızca klasik metin benzerliği metrikleriyle değil, aynı zamanda özeti kaynak metne bağlılığı, tekrar oranı, okunabilirliği, sıkıştırma başarısı ve çalışma süresi gibi pratik kullanım açısından önemli ölçütlerle de incelenmiştir. Üçüncü bileşen ise bu modellerin anlık haber akışı sağlayan bir web uygulamasına entegre edilmesidir. Uygulama, RSS kaynaklarından haberleri toplamakta, haber sayfasından ana metni çıkarmakta, seçilen model ile özet üretmekte, sonuçları veritabanına kaydetmekte ve kullanıcıya filtrelenebilir bir arayüz üzerinden sunmaktadır.

Projenin sınırları da bu kapsamla uyumlu olarak belirlenmiştir. Çalışma, haber metinlerinin otomatik özetlenmesine odaklanmakta; haberlerin doğruluğunu bağımsız biçimde teyit eden bir fact-checking sistemi geliştirmemektedir. Üretilen özetlerin kaynak metne bağlı

kalması için çeşitli temizlik, son işleme ve değerlendirme adımları uygulanmış olsa da sistem, haberin dış dünyadaki olgusal doğruluğunu garanti etmeyi amaçlamamaktadır. Benzer şekilde proje, bütün interneti tarayan genel amaçlı bir arama motoru değildir; önceden tanımlanmış ve doğrulanmış haber kaynaklarından gelen RSS akışları üzerinden çalışmaktadır. Haber sayfasından metin çıkarma işlemi, kaynak sitenin teknik yapısına, erişilebilirliğine ve sayfa şablonuna bağlıdır. Bu nedenle bazı kaynaklarda tam haber gövdesi alınamayabilir veya kaynak kalitesi düşükse sistem ilgili içeriği işlem dışında bırakabilir. Ayrıca çalışma, büyük ölçekli üretim ortamı optimizasyonundan ziyade araştırma ve prototip düzeyinde çalışan, ölçülebilir ve genişletilebilir bir sistem geliştirmeye odaklanmıştır.

Bu projenin temel araştırma problemi şu şekilde ifade edilebilir: Çok dilli haber metinleri için eğitilen veya uyarlanan özetleme modelleri, kalite, kaynak sadakati, hız ve kullanılabilirlik açısından nasıl karşılaştırılabilir ve bu modeller gerçek zamanlı haber akışı sunan bir web uygulamasında nasıl işlevsel biçimde kullanılabilir? Bu problem iki alt soruyu da beraberinde getirmektedir. Birincisi, farklı model mimarileri ve eğitim stratejileri haber özetleme kalitesini nasıl etkilemektedir? İkincisi, model çıktılarının yalnızca akademik değerlendirme ortamında değil, gerçek haber kaynaklarından gelen değişken ve gürültülü metinler üzerinde kullanılabilir olması için nasıl bir sistem tasarımı gereklidir? Proje bu sorulara hem deneysel model değerlendirmesi hem de çalışan uygulama geliştirme yoluyla yanıt aramıştır.

Çalışmanın ana amacı, çok dilli haber özetleme için kullanılabilecek modelleri eğitmek, değerlendirmek, karşılaştırmak ve bu modelleri pratik bir haber akışı uygulamasına entegre ederek uçtan uca çalışan bir prototip ortaya koymaktır. Bu amaç olabildiğince ölçülebilir biçimde tanımlanmıştır. Model başarısı; ROUGE, BLEU ve METEOR benzeri referans özetle örtüşme metrikleriyle, kaynak metne bağlılık ve tekrar oranı gibi ek davranış metrikleriyle, ayrıca tutarlılık, doğruluk, açıklık, alakalılık ve verimlilik boyutlarını temsil eden birleşik kabiliyet skorlarıyla ölçülmüştür. Uygulama başarısı ise sistemin farklı dillerdeki RSS kaynaklarından haber toplayabilmesi, haber gövdesini çıkarabilmesi, model bazlı özetleri üretebilmesi, bu özetleri veritabanında saklayabilmesi ve kullanıcının dil, konu, ülke, bölge, kaynak, anahtar kelime ve model seçimine göre haber-

leri görüntüleyebilmesi üzerinden değerlendirilmiştir. Böylece proje yalnızca “iyi özet üreten model” hedefiyle sınırlı kalmamış; modelin gerçek bir kullanıcı arayüzünde ne kadar kullanılabilir hale getirilebildiğini de ölçmeyi hedeflemiştir.

Projenin özgün değeri, model eğitimi, model değerlendirmesi ve uygulama entegrasyonunu tek bir bütün halinde ele almasından gelmektedir. Haber özetleme üzerine yapılan birçok çalışmada model performansı yalnızca veri kümesi üzerindeki otomatik metriklerle incelenirken, bu projede modellerin gerçek haber akışı içinde nasıl davranacağı da dikkate alınmıştır. RSS kaynaklarından gelen haberler, standart ve temiz akademik veri kümelerindeki metinlerden farklıdır; başlık tekrarları, reklam metinleri, tarih ve yazar bilgileri, sosyal medya bağlantıları, eksik paragraflar ve kaynaklara özgü şablon kalıntıları içerebilir. Bu proje, bu tür gürültülü girdileri temizleyerek özetleme modeline daha uygun hale getiren bir işleme hattı kurmuştur. Ayrıca kaynak metin alınamadığında sistemi tamamen durdurmak yerine kontrollü geri dönüş mekanizmaları kullanılmış, ancak düşük kaliteli veya yetersiz içeriklerin sisteme zarar vermesini engellemek için kalite kapıları tasarlanmıştır.

Özgünlük açısından bir diğer önemli nokta, değerlendirmenin tek boyutlu yapılmamasıdır. Haber özetleme modellerinde yalnızca referans özetle kelime örtüşmesine bakmak yanıltıcı olabilir. Bir model referansa yakın kelimeler üretebilir ancak kaynak metinden kopabilir, gereksiz tekrar yapabilir, çok uzun veya çok kısa özetler üretebilir ya da pratik kullanım için yavaş kalabilir. Bu nedenle projede klasik metriklerin yanında kaynak kapsamı, kaynak geri çağırımı, parça kapsamı, tekrar oranı, sıkıştırma oranı ve gecikme süresi gibi ek ölçümler kullanılmıştır. Bu ölçümler daha sonra tutarlılık, doğruluk, açıklık, alakalılık ve verimlilik gibi daha yorumlanabilir başlıklar altında birleştirilmiştir. Böylece modeller yalnızca akademik skorlarına göre değil, gerçek kullanıcı deneyimine etkisi olacak yönleriyle de karşılaştırılmıştır.

Konunun seçilme nedeni, haber tüketiminde zaman, dil ve güvenilirlik problemlerinin aynı anda ortaya çıkmasıdır. Kullanıcılar çoğu zaman birden fazla kaynağı takip etmek, farklı ülkelerden haberleri görmek, yabancı dildeki içerikleri anlamak ve uzun metinleri kısa sürede kavramak ister. Bununla birlikte otomatik özetleme sistemleri, haber gibi has-

şas bir alanda dikkatli tasarlanmadığında eksik, yanıltıcı veya bağlamdan kopuk çıktılar üretebilir. Bu proje, bu ihtiyacı hem doğal dil işleme hem de yazılım sistemi tasarımı açısından ele alarak anlamlı bir çözüm geliştirmeyi amaçlamıştır. Çok dilli destek, model karşılaştırması ve web uygulaması entegrasyonu birlikte düşünüldüğünde proje, yalnızca deneysel bir model çalışması değil, kullanıcıya dönük bir haber özetleme platformu prototipi niteliği taşımaktadır.

Projenin ana tasarımı, ardışık fakat birbirini besleyen üç katman üzerine kuruludur. İlk katman model katmanıdır. Bu katmanda haber özetleme için uygun transformer tabanlı diziden diziye modeller kullanılmıştır. İngilizce haber özetleme için BART tabanlı modeller, çok dilli haber özetleme için ise mBART ve mT5 tabanlı modeller ele alınmıştır. Proje kapsamında mBART tabanlı iki farklı eğitim hattı oluşturulmuştur. İlk eğitim hattı daha temel ve güvenli bir başlangıç yaklaşımı olarak tasarlanmış, ikinci eğitim hattında ise doğrulama stratejisi, hedef uzunluk, öğrenme oranı, örnekleme yaklaşımı ve en iyi kontrol noktasını seçme gibi kalite odaklı düzenlemeler yapılmıştır. Böylece aynı temel mimari üzerinde farklı eğitim kararlarının model davranışına etkisi karşılaştırılabilir hale getirilmiştir.

İkinci katman değerlendirme katmanıdır. Bu katmanda modeller, çok dilli haber özetleme veri kümesi üzerinde test edilmiştir. Değerlendirmede her modelin farklı dillerdeki çıktıları ayrı ayrı incelenmiş, ardından genel ortalama performansları karşılaştırılmıştır. Klasik metrikler modelin referans özetle ne kadar örtüştüğünü gösterirken, kaynak bağlılığı metrikleri özetin haber metninden ne kadar kopmadığını anlamak için kullanılmıştır. Tekrar oranı ve okunabilirlik sinyalleri özetin kullanıcı tarafından ne kadar rahat okunabileceğine dair fikir vermiştir. Gecikme süresi ve sıkıştırma oranı ise modelin web uygulamasında pratik olarak kullanılabilir olup olmadığını değerlendirmek için önemlidir. Bu yaklaşım, projenin yalnızca model skoru üretmekle kalmayıp, model seçimini uygulama bağlamına göre yapmasını sağlamıştır.

Üçüncü katman uygulama katmanıdır. Web uygulaması Flask tabanlı bir mimariyle geliştirilmiştir. Sistem, farklı diller ve kategoriler için tanımlanmış RSS kaynaklarından haberleri belirli aralıklarla toplar. Toplanan haberlerin bağlantıları üzerinden haber sayfasına

gidilir ve mümkünse tam haber gövdesi çıkarılır. Haber gövdesi temizlendikten sonra seçilen özetleme modellerine gönderilir. Üretilen özetler haber kaydıyla birlikte SQLite veritabanına yazılır. Bu tercih, API çağrısı yapıldığında modelin her seferinde yeniden çalıştırılmasını önleyerek arayüzün daha hızlı yanıt vermesini sağlar. Arka planda çalışan zamanlayıcı, haberleri düzenli aralıklarla işler ve yeni özetleri hazır hale getirir. Kullanıcı arayüzü ise hazır özetleri veritabanından okuyarak dil, konu, ülke, bölge, kaynak, anahtar kelime ve model filtresiyle sunar.

Projede kullanılan yöntemler, amaçlarla doğrudan ilişkilidir. Model eğitimi için transformer tabanlı önceden eğitilmiş modellerin seçilmesi, çok dilli özetleme görevinin yüksek veri ve hesaplama gerektiren yapısından kaynaklanmaktadır. Sıfırdan model eğitmek yerine önceden eğitilmiş modelleri haber özetleme görevine uyarlamak, sınırlı donanım ve süre koşullarında daha gerçekçi bir yaklaşımdır. Değerlendirme için çok sayıda metriğin birlikte kullanılması, haber özetleme kalitesinin tek bir skorla temsil edilememesinden kaynaklanmaktadır. Uygulama tarafında RSS tabanlı veri toplama kullanılması ise haberlerin düzenli, güncel ve kaynak bazlı biçimde alınmasına olanak tanır. SQLite kullanımı prototip düzeyinde yeterli, taşınabilir ve kurulumu kolay bir veri saklama çözümü sağlamıştır. Arka plan ingest mimarisi ise model üretim maliyetini kullanıcı isteği anından ayırarak sistemin daha kullanılabilir olmasına katkı vermiştir.

Kaynak ihtiyaçları açısından proje dört ana gruba ayrılabilir. Birinci grup veri kaynaklarıdır. Model eğitimi ve değerlendirmesi için haber özetleme veri kümeleri, uygulama için ise RSS haber kaynakları kullanılmıştır. İkinci grup yazılım kaynaklarıdır. Python, Flask, transformers, PyTorch, RSS ayrıştırma ve haber gövdesi çıkarma kütüphaneleri projenin temel yazılım bileşenlerini oluşturmuştur. Üçüncü grup donanım kaynaklarıdır. Transformer tabanlı modellerin eğitimi ve değerlendirilmesi GPU gereksinimi doğurmuştur; buna karşılık uygulama tarafında hazır modellerin çalıştırılması için daha sınırlı ama yine de dikkatli yönetilmesi gereken işlemci, bellek ve depolama kaynakları gerekmektedir. Dördüncü grup ise sistem kaynaklarıdır. Haberlerin saklanması için veritabanı, model dosyalarının tutulması için yerel depolama, arka plan işlerinin izlenmesi için loglama ve düzenli ingest için zamanlayıcı altyapısı kullanılmıştır.

Projeden elde edilen sonuçlar, model seçiminin tek bir metrik üzerinden yapılamayacağını göstermiştir. Hazır mT5 tabanlı model genel değerlendirmede güçlü bir karşılaştırma noktası oluşturmuş ve birçok klasik metrikte yüksek sonuçlar vermiştir. Proje kapsamında eğitilen iki mBART modeli ise birbirine yakın genel performans göstermiş, ancak davranış profilleri farklılaşmıştır. İlk mBART modeli kaynak metne daha bağlı ve daha güvenli özetler üretme eğilimindeyken, ikinci mBART modeli bazı klasik örtüşme metriklerinde ve hız tarafında küçük avantajlar sağlamıştır. Bu sonuç, haber özetleme sistemlerinde “en iyi model” kararının kullanım amacına bağlı olduğunu ortaya koymaktadır. Eğer öncelik kaynak sadakati ve daha düşük olgusal risk ise daha kaynak-bağlı model tercih edilebilir. Eğer öncelik daha hızlı, daha kısa ve daha serbest yeniden ifade edilen özetler ise diğer model daha uygun olabilir.

Uygulama entegrasyonu açısından proje, model çıktılarının gerçek haber akışı üzerinde kullanılabilir hale getirilebildiğini göstermiştir. Sistem, farklı dillerdeki kaynakları okuyabilmekte, haber metinlerini çıkarabilmekte, özetleri model bazlı olarak önceden hesaplayabilmekte ve kullanıcıya filtrelenebilir bir arayüzde sunabilmektedir. Ayrıca çeviri desteği, görsel gösterimi, kaynak bağlantısı, anahtar kelime araması, konu ve bölge filtreleri gibi özellikler uygulamayı yalnızca teknik bir demo olmaktan çıkarıp daha işlevsel bir haber takip aracına yaklaştırmıştır. Arka planda çalışan ingest yapısı sayesinde haber toplama ve özet üretme işlemleri düzenli biçimde yapılmakta, API ise kullanıcıya hazır sonuçları döndürmektedir. Bu mimari, özetleme modellerinin yüksek çalışma maliyetini azaltmak ve kullanıcı deneyimini iyileştirmek açısından önemlidir.

Genel olarak proje, çok dilli haber özetleme problemini model, değerlendirme ve uygulama eksenlerinde ele almıştır. Çalışma sonucunda farklı özetleme modellerinin güçlü ve zayıf yönleri ölçülmüş, bu modellerin gerçek haber kaynaklarıyla çalışan bir sistem içinde nasıl kullanılabileceği gösterilmiş ve kullanıcıya dönük bir web uygulaması prototipi geliştirilmiştir. Projenin en önemli çıktısı, haber özetleme kalitesinin yalnızca referans metin benzerliğiyle değil, kaynak sadakati, okunabilirlik, tekrar oranı, hız ve sistem entegrasyonu gibi çok boyutlu ölçütlerle değerlendirilmesi gerektiğini göstermesidir. Bu yönüyle proje, hem doğal dil işleme alanında deneysel bir çalışma hem de gerçek kullanım senaryosuna yaklaşan bir yazılım sistemi geliştirme çalışması olarak değerlendirilebilir.

1 INTRODUCTION

Aujourd’hui, la production et la consommation d’actualités sont devenues rapides, multilingues et liées à de nombreuses sources. Les utilisateurs veulent suivre non seulement les nouvelles de leur propre pays, mais aussi les événements internationaux publiés dans d’autres langues. Cependant, le grand nombre de sources, la répétition des mêmes sujets, la longueur des articles et la difficulté d’accéder aux contenus étrangers rendent l’accès rapide à une information claire plus difficile. Le résumé automatique de nouvelles répond à ce besoin en produisant un texte plus court, lisible et informatif à partir d’un article long. Ce projet vise à développer un système complet qui résume automatiquement des articles multilingues, compare les modèles entraînés dans le projet avec un modèle prêt à l’emploi entraîné dans une étude similaire, et intègre ces modèles dans une application web de flux d’actualités en temps réel.

Un autre aspect original est la conception d’une évaluation multidimensionnelle avec de nouveaux scores proxy. Les métriques classiques comme ROUGE, BLEU ou METEOR sont utiles, mais elles ne suffisent pas pour juger complètement la qualité d’un résumé d’actualité. Un bon résumé doit aussi rester fidèle au texte source, éviter les répétitions, être clair, couvrir l’information importante et être produit dans un temps raisonnable. Pour cette raison, le projet utilise aussi des mesures comme la couverture de la source, le rappel de la source, le taux de répétition, le taux de compression et le temps de génération. À partir de ces signaux, des scores de cohérence, d’exactitude, de clarté, de pertinence et d’efficacité ont été créés. Cette approche permet de répondre non seulement à la question « quel modèle obtient le meilleur score classique ? », mais aussi à la question « quel modèle convient le mieux à tel usage ? ».

Les méthodes utilisées peuvent être regroupées en trois étapes principales. La première étape est la préparation et l’entraînement des modèles. Des modèles transformer de type séquence-à-séquence basés sur BART, mBART et mT5 ont été étudiés. Les modèles BART ont été considérés pour le résumé en anglais, tandis que les modèles mBART ont été utilisés pour le résumé multilingue. Plusieurs choix d’entraînement ont été testés pour

mBART, comme le jeu de données, la longueur cible du résumé, le taux d'apprentissage, l'optimisation, la validation et le choix du meilleur checkpoint. Le modèle mT5 n'est pas un résultat de cet entraînement ; il a été pris comme modèle prêt à l'emploi entraîné dans une étude similaire et utilisé comme point de comparaison.

La deuxième étape est l'évaluation et la comparaison des modèles. Les modèles mBART entraînés dans le projet et le modèle mT5 prêt à l'emploi ont été testés dans les mêmes conditions. Les résultats de mT5 ne représentent donc pas un résultat d'entraînement du projet, mais une référence permettant de situer les modèles mBART face à un modèle déjà fort. Pendant cette évaluation, les métriques classiques ont été complétées par des scores proxy composites. Ces scores ont été conçus pour mesurer des dimensions que les métriques classiques ne capturent pas seules.

Dans ce cadre, les scores de cohérence, d'exactitude, de clarté, de pertinence et d'efficacité ont été calculés séparément, puis combinés dans une valeur générale appelée capability overall. Le score quality factuality a été utilisé pour mesurer la fidélité du résumé au texte source, tandis que quality completeness a servi à évaluer la couverture du contenu de référence et l'adaptation de la longueur du résumé. Ces scores ne remplacent pas une évaluation humaine, mais ils permettent une comparaison automatique, répétable et plus détaillée des modèles.

La troisième étape est l'intégration des modèles dans l'application web. Une application basée sur Flask a été développée. Elle collecte des flux RSS pour différentes langues et catégories, extrait le texte principal des articles, nettoie les contenus et envoie les textes aux modèles de résumé. Les résumés produits sont enregistrés dans une base de données SQLite avec les informations sur l'article, la source, la langue, le modèle et la date. L'interface utilisateur lit ensuite les résumés déjà préparés, ce qui évite de relancer le modèle à chaque requête. L'application propose des filtres par langue, sujet, région, pays, source, mot-clé et modèle, ainsi que des options comme la traduction et l'affichage d'images.

La conception du système repose aussi sur une architecture d'ingestion en arrière-plan. Au lieu de collecter et résumer les articles au moment exact de la demande utilisateur, le

système traite régulièrement les nouvelles avec un planificateur. Celui-ci collecte les articles candidats depuis les flux RSS, équilibre le traitement entre les sources et les langues, extrait les textes, produit les résumés et les enregistre dans la base de données. Cette approche réduit le temps d'attente pour l'utilisateur et rend l'application plus stable.

La contribution scientifique du projet est l'évaluation des modèles de résumé multilingue avec un cadre plus large qu'une seule métrique de performance. Les nouveaux scores proxy permettent d'analyser la qualité selon plusieurs aspects : cohérence, exactitude, clarté, pertinence, efficacité, fidélité à la source et complétude du contenu. L'étude permet aussi d'observer comment différentes stratégies d'entraînement influencent le comportement de modèles mBART. L'ajout du modèle mT5 entraîné dans une étude similaire donne un point de comparaison fort et rend l'analyse plus significative.

Les principaux résultats du projet sont regroupés en trois catégories. Le premier résultat est la création et l'utilisation de modèles mBART multilingues entraînés dans le cadre du projet. Le modèle mT5 prêt à l'emploi n'est pas un résultat d'entraînement du projet ; il a été ajouté uniquement pour la comparaison. Le deuxième résultat est l'évaluation comparative des modèles avec des métriques classiques et des scores proxy. Le troisième résultat est une application web fonctionnelle qui collecte les actualités, produit les résumés, les stocke dans une base de données et les présente à l'utilisateur.

Les résultats montrent que le modèle mT5 prêt à l'emploi constitue un point de comparaison fort, tandis que les modèles mBART entraînés dans le projet produisent des profils utiles pour différents scénarios. Le fait que mT5 obtienne de meilleurs scores sur certaines mesures ne doit pas être interprété comme un échec des modèles du projet, mais comme une comparaison avec un modèle déjà entraîné et solide. Entre les modèles mBART, le choix dépend des priorités : fidélité à la source, vitesse, similarité avec la référence ou équilibre général. Le projet montre donc que le choix du modèle doit dépendre de l'usage visé.

Le plan de travail a été réalisé par étapes. D'abord, la problématique a été définie et le périmètre du projet a été limité au résumé multilingue, à la comparaison de modèles et à l'intégration web. Ensuite, les jeux de données, les sources RSS et les modèles candidats

basés sur BART, mBART et mT5 ont été étudiés. Puis, les modèles mBART ont été entraînés avec différents paramètres et rendus utilisables localement ; le modèle mT5, déjà entraîné dans une étude similaire, a été ajouté comme modèle de comparaison. Après cela, le processus d'évaluation a été conçu avec les métriques classiques, les métriques de fidélité à la source, de lisibilité, de répétition, de compression, de temps de génération et les nouveaux scores proxy. Les modèles ont ensuite été testés dans les mêmes conditions et leurs résultats ont été comparés. Dans l'étape suivante, l'application web a été développée avec le pool RSS, l'extraction des textes, le nettoyage, la génération de résumés, SQLite, le planificateur d'ingestion et les endpoints API. Enfin, l'interface utilisateur a été préparée, le système a été testé de bout en bout, puis les résultats expérimentaux et les contributions scientifiques, technologiques, éthiques et socioéconomiques ont été analysés.

2 REVUE DE LITTERATURE

Le résumé automatique est un domaine important du traitement automatique du langage naturel. Son objectif est de produire une version plus courte d'un texte tout en conservant les informations principales. Les premières approches étaient surtout extractives: elles sélectionnaient les phrases les plus importantes du document source et les assemblaient pour former un résumé. Ces méthodes étaient utiles pour réduire rapidement la taille d'un texte, mais elles produisaient souvent des résumés peu naturels, avec des répétitions ou une cohérence limitée entre les phrases. Avec le développement des modèles neuronaux, le résumé abstractive est devenu plus central. Dans cette approche, le modèle ne copie pas seulement des phrases du texte source; il peut reformuler l'information et produire de nouvelles phrases plus proches d'un résumé humain Nallapati et al. (2016); See et al. (2017).

Les travaux de Nallapati et al. ont montré que les architectures séquence-à-séquence pouvaient être adaptées au résumé abstractive, mais aussi que cette tâche restait difficile à cause de la longueur des documents, de la sélection de l'information et de la génération d'un texte cohérent Nallapati et al. (2016). See et al. ont ensuite proposé les réseaux pointer-generator, qui combinent génération et copie depuis la source. Cette idée est importante pour les résumés d'actualités, car les noms propres, les lieux, les chiffres et les événements doivent souvent être repris fidèlement depuis le texte original See et al. (2017). Ces travaux montrent déjà une tension centrale pour notre projet: un bon système de résumé doit être capable de reformuler, mais il doit aussi rester proche de la source pour éviter les erreurs factuelles.

Dans le contexte du présent projet, cette évolution justifie le choix de modèles de génération modernes. Le but n'est pas seulement de raccourcir un article, mais de produire un résumé lisible, informatif et utilisable dans une application web. Les approches extractives simples peuvent être utiles comme solution de secours, mais elles ne suffisent pas pour obtenir des résumés fluides dans plusieurs langues. C'est pourquoi le projet s'appuie principalement sur des modèles transformer séquence-à-séquence, tout en gardant des mé-

canismes de contrôle comme le nettoyage des textes, le post-traitement et l'évaluation de la fidélité à la source.

2.1 Résumé d'actualités et spécificités du domaine

Le résumé d'actualités est un cas particulier du résumé automatique. Les articles de presse contiennent souvent des informations factuelles, des dates, des noms de personnes, des lieux, des citations et des chiffres. Une erreur dans un résumé d'actualité peut donc modifier le sens de l'information. Les jeux de données comme CNN/Daily Mail, XSum, Newsroom et Multi-News ont joué un rôle important dans le développement des modèles de résumé pour le domaine journalistique Hermann et al. (2015); Narayan et al. (2018); Grusky et al. (2018); Fabbri et al. (2019). CNN/Daily Mail a été largement utilisé pour des résumés relativement extractifs, alors que XSum se concentre sur des résumés courts et plus abstraits, souvent proches d'une phrase de synthèse Narayan et al. (2018).

Le jeu de données Newsroom est particulièrement utile pour comprendre que les résumés d'actualités ne sont pas tous du même type. Grusky et al. montrent que certains résumés sont très proches du texte source, tandis que d'autres reformulent davantage l'information Grusky et al. (2018). Cette observation est directement liée à notre projet: les modèles peuvent avoir des comportements différents selon leur degré d'extractivité, leur capacité à reformuler et leur fidélité au texte original. Un modèle très extractif peut être plus prudent, mais moins naturel; un modèle plus abstrait peut être plus fluide, mais aussi plus risqué du point de vue factuel.

Ces travaux montrent aussi une limite importante de la littérature: beaucoup d'études évaluent les modèles sur des jeux de données fixes et propres, alors que les textes provenant de flux RSS et de sites d'actualités réels sont plus variables. Ils peuvent contenir des titres répétés, des informations de navigation, des éléments publicitaires, des phrases incomplètes ou des structures HTML complexes. Le présent projet cherche à réduire cet écart entre évaluation académique et usage pratique en intégrant les modèles dans une application qui collecte de vrais articles, extrait le corps du texte, nettoie les contenus et produit des résumés utilisables par l'utilisateur final.

2.2 Modèles transformer pour le résumé

Les modèles transformer ont profondément transformé les tâches de génération de texte. Contrairement aux architectures récurrentes, ils gèrent mieux les dépendances longues et peuvent être pré-entraînés sur de grands corpus avant d'être adaptés à une tâche spécifique. BART est l'un des modèles les plus importants pour le résumé abstractive. Il est pré-entraîné comme un autoencodeur dénoisant: le modèle apprend à reconstruire un texte original à partir d'une version dégradée, ce qui le rend efficace pour des tâches de génération comme le résumé Lewis et al. (2020). Cette logique explique pourquoi les modèles BART sont souvent utilisés comme base pour le résumé d'articles en anglais.

PEGASUS propose une autre stratégie de pré-entraînement, plus directement orientée vers le résumé. Le modèle apprend à prédire des phrases importantes supprimées d'un document, ce qui rapproche le pré-entraînement de la tâche finale de summarisation Zhang et al. (2020). Même si PEGASUS n'est pas le modèle central de notre implémentation, cette étude montre que la qualité d'un modèle de résumé dépend non seulement de son architecture, mais aussi de la manière dont il est pré-entraîné et adapté à la tâche.

Dans notre projet, les modèles BART servent surtout de référence pour le résumé en anglais, tandis que l'objectif principal est le résumé multilingue. Cette distinction est importante: un modèle performant en anglais ne peut pas être directement considéré comme une solution générale pour des langues comme le turc, l'arabe, le russe, le chinois ou le vietnamien. Pour couvrir plusieurs langues dans une même application, il faut utiliser des modèles pré-entraînés sur des données multilingues et capables de générer dans différentes langues.

2.3 Modèles multilingues et résumé multilingue

Les modèles multilingues comme mBART, mBART-50 et mT5 sont centraux pour le présent projet. mBART étend l'idée du pré-entraînement dénoisant à plusieurs langues. Le modèle apprend des représentations partagées qui peuvent ensuite être adaptées à des tâches de génération multilingues Liu et al. (2020). mBART-50 augmente encore cette ca-

pacité en couvrant davantage de langues et en facilitant le transfert multilingue Tang et al. (2020). Ces caractéristiques rendent mBART adapté au résumé d’actualités multilingue, car un même cadre de modèle peut être utilisé pour plusieurs langues.

mT5 suit une autre approche: il adapte le modèle text-to-text T5 à un contexte massivement multilingue Xue et al. (2021). Dans notre projet, le modèle mT5 utilisé pour la comparaison n’a pas été entraîné dans le cadre du projet. Il a été pris comme modèle déjà entraîné dans une étude similaire et sert de référence externe. Cette distinction est importante pour l’interprétation des résultats: mT5 permet de situer les modèles mBART entraînés dans le projet face à un modèle multilingue fort, mais il ne doit pas être présenté comme une sortie de notre propre processus d’entraînement.

Les jeux de données multilingues jouent aussi un rôle essentiel. XL-Sum est l’un des principaux jeux de données pour le résumé abstractive multilingue d’actualités. Il couvre un grand nombre de langues et fournit des couples article-résumé adaptés à l’entraînement et à l’évaluation de modèles multilingues Hasan et al. (2021). MLSUM est un autre corpus multilingue important, construit à partir d’articles de presse dans plusieurs langues européennes Scialom et al. (2020). Ces ressources montrent que le résumé multilingue est devenu un sujet important, mais elles restent principalement utilisées dans des évaluations hors ligne. Notre projet complète cette perspective en reliant l’évaluation multilingue à une application web qui traite des flux d’actualités réels.

2.4 Évaluation automatique des résumés

L’évaluation est l’un des problèmes les plus importants dans le résumé automatique. Les métriques classiques comme ROUGE, BLEU et METEOR sont très utilisées parce qu’elles permettent une comparaison automatique et reproductible Lin (2004); Papineni et al. (2002); Banerjee & Lavie (2005). ROUGE mesure principalement le recouvrement de n-grammes entre le résumé produit et le résumé de référence. BLEU, proposé initialement pour la traduction automatique, mesure aussi la correspondance de n-grammes. METEOR ajoute une forme plus flexible de correspondance entre tokens et peut mieux tenir compte de certaines variations lexicales.

Cependant, ces métriques ont des limites importantes pour le résumé d'actualités. Un résumé peut obtenir un bon score ROUGE parce qu'il partage des mots avec la référence, mais il peut quand même être incomplet, répétitif ou peu fidèle au texte source. À l'inverse, un résumé bien formulé peut utiliser des mots différents de la référence et recevoir un score plus faible. SummEval montre que l'évaluation du résumé doit prendre en compte plusieurs dimensions, notamment la cohérence, la pertinence, la fluidité et la cohérence factuelle Fabbri et al. (2021). Cette observation soutient directement la méthode adoptée dans notre projet.

Une étude récente de Miller et Tang renforce aussi cette critique des évaluations classiques. Les auteurs soutiennent que les métriques appliquées aux modèles génératifs doivent être alignées avec les usages réels plutôt qu'avec des benchmarks abstraits Miller & Tang (2025). Leur analyse propose d'examiner les capacités des modèles selon des critères pratiques comme la cohérence, l'exactitude, la clarté, la pertinence et l'efficacité. Cette perspective est directement liée au présent projet, car les scores proxy utilisés dans l'évaluation des modèles de résumé cherchent également à mesurer des dimensions proches de l'usage réel, au-delà du simple recouvrement lexical.

2.5 Fidélité factuelle et hallucination dans les résumés

La fidélité factuelle est un enjeu majeur pour le résumé abstractive. Les modèles génératifs peuvent produire des informations qui ne sont pas présentes dans le texte source, modifier des relations causales, confondre des entités ou changer des chiffres. Maynez et al. montrent que les résumés abstractifs peuvent contenir des erreurs factuelles même lorsqu'ils semblent bien formés linguistiquement Maynez et al. (2020). Ce problème est particulièrement sensible pour les actualités, car l'utilisateur peut prendre le résumé comme une représentation rapide d'un événement réel.

Plusieurs travaux ont proposé des méthodes pour mesurer ou détecter ces inconsistances. FactCC utilise une approche de classification pour évaluer la cohérence factuelle entre un document et son résumé Kryscinski et al. (2020). SummaC s'appuie sur des modèles d'inférence en langue naturelle pour détecter les contradictions ou les inconsistances La-

ban et al. (2022). QuestEval propose une évaluation basée sur des questions et réponses afin d'examiner si les informations importantes du texte source sont bien préservées Scialom et al. (2021). Ces travaux montrent que la fidélité ne peut pas être réduite à un simple recouvrement lexical.

Le présent projet ne construit pas un système complet de fact-checking, mais il prend en compte ce problème dans sa méthode. Le score *quality factuality*, la couverture de la source et les mesures de fragments extraits servent de proxy pour estimer si le résumé reste proche du texte original. De plus, l'application conserve le lien vers l'article source afin que l'utilisateur puisse vérifier le contexte complet. Cette décision est importante sur le plan méthodologique et éthique: le résumé est présenté comme une aide à la lecture rapide, non comme un remplacement définitif de l'article.

2.6 Systèmes de résumé d'actualités et intégration applicative

La littérature contient aussi des travaux sur les systèmes de résumé d'actualités. Newsblaster est un exemple ancien mais important: il collectait automatiquement des nouvelles, les groupait par sujet et produisait des résumés pour aider les utilisateurs à suivre l'actualité McKeown et al. (2002). MEAD a également proposé une plateforme pour le résumé multi-document et multilingue, avec une attention particulière aux systèmes configurables Radev et al. (2004). Ces systèmes montrent que le résumé automatique n'est pas seulement un problème de modèle, mais aussi un problème d'architecture, de collecte, de filtrage et de présentation des résultats.

Notre projet s'inscrit dans cette tradition applicative, mais avec des modèles neuronaux modernes et une architecture orientée flux RSS. L'application développée collecte les articles à partir de sources définies, extrait le texte principal, nettoie les données, génère des résumés avec plusieurs modèles et stocke les résultats dans une base SQLite. L'utilisation d'un processus d'ingestion en arrière-plan évite de faire attendre l'utilisateur pendant la génération du résumé. Cette approche répond à une limite pratique souvent absente des évaluations académiques: un modèle doit non seulement produire de bons scores, mais aussi fonctionner dans un système interactif avec des contraintes de temps.

3 DEFINITION DU PROBLEME

Aujourd'hui, les contenus d'actualité sont produits en continu et à grande vitesse par un grand nombre de sources numériques. Les utilisateurs veulent suivre des nouvelles venant de différents pays, de différentes langues et de différents domaines. Cependant, la longueur des articles, le nombre élevé de sources, la répétition du même événement sous plusieurs formes et la difficulté d'accéder aux contenus en langues étrangères rendent l'accès rapide à l'information plus difficile. Cette situation augmente le besoin de systèmes capables de présenter, dans les flux d'actualités numériques, des résumés courts, compréhensibles, fiables et liés à leur source originale.

Ce besoin est aussi confirmé par les données récentes sur la consommation de l'information. Le *Digital News Report 2025*, publié par le Reuters Institute, s'appuie sur des données provenant de six continents et de 48 marchés. Il montre que la consommation des actualités devient de plus en plus fragmentée, centrée sur les plateformes et marquée par un problème de confiance. Selon ce rapport, 58 % des participants se disent inquiets de ne pas pouvoir distinguer ce qui est vrai et ce qui est faux dans les informations en ligne. Le même rapport indique aussi que les utilisateurs voient certains usages de l'intelligence artificielle comme utiles pour rendre l'actualité plus accessible: 27 % des participants trouvent utile l'utilisation de l'IA pour résumer les nouvelles, et 24 % pour traduire les nouvelles dans d'autres langues Newman et al. (2025). De façon similaire, le *Digital News Report 2024* montre qu'environ 39 % des participants évitent parfois ou souvent les nouvelles, et que le sentiment d'être surchargé par la quantité d'informations a augmenté par rapport aux années précédentes Newman et al. (2024). Ces résultats montrent que le résumé multilingue d'actualités, la fidélité à la source et la présentation rapide de résumés accessibles ne sont pas seulement des problèmes techniques, mais aussi des questions liées aux habitudes actuelles de consommation de l'information.

Le problème principal traité par ce projet est le résumé automatique de textes d'actualité multilingues, la comparaison objective de différents modèles de résumé et l'intégration de ces modèles dans une application web fournissant un flux d'actualités en temps réel.

Le problème ne consiste pas seulement à raccourcir un article. Il faut aussi extraire correctement le corps de l'article, rendre le texte utilisable par le modèle, produire un résumé fidèle au texte source, réduire les répétitions et la perte d'information, obtenir des résultats acceptables dans plusieurs langues et permettre au système de répondre à l'utilisateur dans un temps raisonnable.

Dans ce contexte, la question de recherche du projet peut être formulée ainsi: comment évaluer des modèles de résumé d'actualités multilingues selon la qualité, la fidélité à la source, la lisibilité, la couverture de l'information, la vitesse et l'utilisabilité pratique, et comment appliquer ces modèles dans un flux d'actualités provenant de sources réelles? Cette question possède deux dimensions principales: le développement des modèles et la conception du système. Du côté du développement des modèles, le projet analyse les performances des modèles basés sur mBART entraînés dans le cadre du projet et les compare avec un modèle mT5 prêt à l'emploi, déjà entraîné dans une étude similaire. Du côté de la conception du système, le projet traite la collecte des actualités depuis des sources RSS, l'extraction du texte des articles, la génération des résumés, leur stockage dans une base de données et leur présentation dans une interface web.

Un aspect important du problème est que la qualité d'un résumé ne peut pas être mesurée par une seule métrique. Les métriques classiques comme ROUGE, BLEU et METEOR sont utiles pour mesurer le recouvrement lexical ou phrastique avec un résumé de référence. Cependant, dans le contexte du résumé d'actualités, elles ne représentent pas suffisamment des dimensions comme la fidélité au texte source, le taux de répétition, la clarté, la pertinence, la qualité de la compression et le temps de génération. Pour cette raison, le projet utilise, en plus des métriques classiques, des scores proxy représentant des dimensions comme la cohérence, l'exactitude, la clarté, la pertinence, l'efficacité, la fidélité à la source et la complétude du contenu. Ainsi, le problème n'est pas traité seulement avec la question "quel modèle obtient le meilleur score classique?", mais aussi avec la question "quel modèle produit les résumés les plus adaptés à un scénario d'utilisation réel?".

Un autre aspect important du problème est la différence entre les jeux de données académiques et les flux d'actualités réels. Les jeux de données d'évaluation sont généralement com-

posés de textes propres et bien structurés, alors que les données provenant de sources d'actualités réelles peuvent contenir des structures HTML variées, des contenus incomplets, des textes publicitaires ou de navigation, des répétitions de titres et des problèmes de format propres à chaque source. Le problème du projet ne se limite donc pas à mesurer la performance des modèles; il inclut aussi la mise en place d'une chaîne de traitement capable de fonctionner avec des textes bruités provenant de sources réelles. Dans ce cadre, l'extraction du corps des articles, le nettoyage du texte, la génération des résumés, les mécanismes de repli en cas d'échec et la conservation du lien vers la source sont des éléments essentiels du système.

En conclusion, ce projet traite à la fois le problème du choix et de l'évaluation des modèles dans le résumé d'actualités multilingue, et le problème de leur intégration dans une application en temps réel. La solution attendue est un prototype de bout en bout capable de collecter des actualités dans plusieurs langues, de les résumer, d'évaluer les sorties des modèles avec des métriques multidimensionnelles et de les présenter à l'utilisateur dans une interface web filtrable. Cette approche relie l'évaluation traditionnelle sur jeux de données fixes avec les exigences d'un flux d'actualités réel et de l'utilisabilité applicative, ce qui constitue le cœur du problème traité par le projet.

4 METHODOLOGIES

4.1 Approche méthodologique générale

La conception méthodologique de ce projet repose sur trois couches principales: la préparation et l'entraînement des modèles, l'évaluation des modèles avec des métriques multidimensionnelles, et l'intégration des modèles sélectionnés dans une application web fournissant un flux d'actualités en temps réel. Cette structure permet au projet de ne pas rester seulement une étude d'entraînement de modèle, mais de devenir un système de bout en bout fonctionnant avec de vraies sources d'actualités.

Dans la première couche, des modèles transformeurs de type séquence-à-séquence adaptés au résumé d'actualités ont été étudiés, et des modèles multilingues basés sur mBART ont été entraînés dans le cadre du projet. Des modèles basés sur BART ont aussi été préparés pour des expériences de résumé en anglais, mais l'objectif principal du scénario multilingue reste les modèles mBART. Le modèle basé sur mT5 n'a pas été réentraîné dans ce projet; il a été pris comme modèle prêt à l'emploi, déjà entraîné dans une étude similaire, et utilisé pour la comparaison.

Dans la deuxième couche, les modèles ont été évalués non seulement avec des métriques classiques de similarité textuelle, mais aussi avec des signaux supplémentaires comme la fidélité à la source, le comportement de répétition, la lisibilité, la couverture de l'information, la compression et le temps d'exécution. Pour cette raison, en plus des métriques classiques comme ROUGE, BLEU et METEOR-lite, des scores proxy composites ont été définis dans le cadre du projet. Dans la troisième couche, les modèles ont été intégrés dans une application qui collecte des nouvelles depuis des sources RSS, extrait le corps des articles, pré-calcule les résumés, les stocke dans une base SQLite et les présente à l'utilisateur via une interface web.

Figure 4.1 présente le flux méthodologique général du projet.

Des sources de données orientées vers le résumé d'actualités ont été utilisées pour l'entraînement et l'évaluation des modèles. La famille XL-Sum constitue la source principale pour le ré-




Figure 4.1: Flux méthodologique général du projet

sumé multilingue. Dans la première chaîne d’entraînement mBART, le jeu de données GEM/xlsum a été utilisé. Dans la deuxième chaîne d’entraînement mBART, le jeu de données csebuetnlp/xlsum a été préféré. Ce choix a permis de construire une deuxième chaîne plus proche de l’organisation de XL-Sum et de ses longueurs cibles de résumé.

Le plan d’évaluation du projet contient 15 langues: anglais, turc, français, allemand, espagnol, italien, russe, arabe, hindi, chinois, japonais, coréen, néerlandais, roumain et vietnamien. Cependant, dans la version publique utilisée de csebuetnlp/xlsum, les sous-ensembles correspondant à l’allemand, l’italien, le néerlandais et le roumain n’étaient pas disponibles; ces langues ont donc été ignorées dans l’exécution d’évaluation. L’évaluation complète finale a été réalisée sur 11 langues et 52.219 exemples de test.

Dans la couche applicative, la source de données n’est pas un jeu de données académique fixe, mais des sources d’actualités RSS. Le système collecte les entrées RSS définies pour chaque langue, ouvre le lien de l’article, tente d’extraire le corps complet de l’article et envoie le texte nettoyé au modèle de résumé. Ainsi, un lien est établi entre les jeux de données réguliers utilisés pour l’entraînement et l’évaluation, et les flux d’actualités réels utilisés dans l’application.

Tableau 4.1: Familles de modèles utilisées dans le projet

Groupe de modèles	Clés de modèle	Rôle dans le projet
Modèles basés sur BART	bart_large_cnn, bart_base_cnn, bart_reuters	Modèles préparés pour le résumé d’actualités en anglais. Ils sont utilisés pour des expériences et comparaisons en anglais, pas comme solution principale multilingue.
Modèles basés sur mBART	mbart50_xlsum, mbart-xlsum-2	Modèles multilingues entraînés dans le cadre du projet. Ils constituent la sortie principale du développement de modèles.
Modèle basé sur mT5	mt5-xlsum	Modèle non entraîné dans ce projet. Il est utilisé comme modèle de comparaison prêt à l’emploi, entraîné dans une étude similaire.

4.2 Familles de modèles et choix des modèles

Les modèles utilisés dans le projet sont regroupés en trois catégories. La première catégorie contient les modèles basés sur BART pour le résumé d’actualités en anglais. Elle comprend les modèles `bart_large_cnn`, `bart_base_cnn` et `bart_reuters`. La deuxième catégorie contient les modèles multilingues basés sur mBART entraînés dans le cadre du projet: `mbart50_xlsum` et `mbart-xlsum-2`. La troisième catégorie correspond au modèle mT5 prêt à l’emploi utilisé pour la comparaison: `mt5-xlsum`.

Tableau 4.1 résume les groupes de modèles utilisés dans le projet.

Dans l’application, seuls les modèles multilingues sont autorisés pour les langues autres que l’anglais. Cela évite d’appeler par erreur des modèles BART entraînés pour l’anglais sur des textes turcs, arabes, chinois ou dans d’autres langues. Le modèle par défaut de l’application est `mbart50_xlsum`; le jeu de modèles par défaut pour la génération en

arrière-plan contient `mbart50_xlsum`, `mbart-xlsum-2` et `mt5-xlsum`.

4.2.1 Première chaîne d’entraînement mBART

Dans la première chaîne d’entraînement mBART, le modèle de base `mbart-large-50-many-to-many-mmt` a été utilisé. Le jeu de données GEM/xlsum a été choisi comme source de données. Les exemples de différentes langues ont été combinés et un code de langue mBART a été ajouté à chaque exemple. La longueur maximale des textes sources a été fixée à 512 tokens, et la longueur maximale des résumés cibles à 96 tokens.

Cette chaîne d’entraînement a été conçue comme un premier entraînement sur Colab, prudent et exécutable. L’entraînement a été réalisé sur 2 epochs avec un taux d’apprentissage de 3×10^{-5} . L’évaluation basée sur la génération a été désactivée pendant l’entraînement, et le choix du meilleur checkpoint n’a pas été appliqué. Cette décision a été prise pour réduire le coût de calcul et obtenir une première sortie de modèle multilingue.

4.2.2 Deuxième chaîne d’entraînement mBART

La deuxième chaîne d’entraînement mBART a été conçue avec une priorité plus forte sur la qualité. Elle utilise encore le modèle de base `mbart-large-50-many-to-many-mmt`, mais le jeu de données est remplacé par `csebuetnlp/xlsum`. La longueur cible des résumés a été réduite à 64 tokens afin d’adopter un objectif de génération plus proche de XL-Sum.

Dans cette deuxième chaîne, l’entraînement a été organisé par nombre d’étapes plutôt que par nombre d’epochs. Le nombre total d’étapes a été fixé à 35.000, le taux d’apprentissage à 1×10^{-4} et le nombre d’étapes de warmup à 5.000. L’optimizer `adafactor` et le scheduler `inverse_sqrt` ont été utilisés. Le modèle a été évalué et sauvegardé toutes les 5.000 étapes. L’évaluation basée sur la génération a été activée et le meilleur modèle a été choisi selon la valeur ROUGE-L.

Dans cette chaîne, un rééchantillonnage par langue a aussi été appliqué pour rendre les langues à faibles ressources plus visibles pendant l’entraînement. La probabilité d’entraînement de chaque langue est définie comme proportionnelle au nombre d’exemples

Tableau 4.2: Principales différences entre les chaînes d’entraînement mBART

Caractéristique	mbart50_xlsum	mbart-xlsum-2
Modèle de base	facebook/mbart-large-50-many-to-many- mt	facebook/mbart-large-50-many-to-many- mt
Jeu de données	GEM/xlsum	csebuetnlp/xlsum
Longueur source	512 tokens	512 tokens
Longueur cible	96 tokens	64 tokens
Durée d’entraînement	2 epochs	35.000 étapes
Taux d’apprentissage	3×10^{-5}	1×10^{-4}
Optimizer / scheduler	Paramètres Trainer par défaut	adafactor + inverse_sqrt
Validation	Évaluation générée désactivée	Évaluation générée toutes les 5.000 étapes
Choix du checkpoint	Pas de sélection du meilleur modèle	Meilleur checkpoint selon ROUGE-L
Équilibrage linguistique	Mélange standard	Smoothing linguistique avec $\alpha = 0.5$

de cette langue élevé à la puissance α :

$$p_l = \frac{n_l^\alpha}{\sum_{j \in L} n_j^\alpha} \quad (1)$$

Ici, L représente l’ensemble des langues, n_l le nombre d’exemples d’entraînement dans la langue l , et p_l la probabilité de rééchantillonnage de cette langue. Dans le projet, $\alpha = 0.5$ a été choisi. Cette valeur réduit la domination des langues à fortes ressources tout en augmentant la représentation des langues à faibles ressources.

Tableau 4.2 présente les principales différences entre les deux chaînes d’entraînement mBART.

4.3 Méthode de génération des résumés

Dans l'application, la génération des résumés est réalisée avec des paramètres de génération qui dépendent de la famille du modèle et de la langue. Les textes sources sont d'abord nettoyés et limités à une fenêtre d'entrée de 3.500 caractères. Lors de la tokenisation, les entrées sont limitées à 1.024 tokens. Pour les modèles mBART, le code de langue source approprié est configuré et `forced_bos_token_id` est utilisé pour orienter la génération vers la langue cible.

Les paramètres généraux de génération comprennent la longueur maximale du résumé, la longueur minimale, le nombre de beams, la pénalité de longueur, l'interdiction de répétitions et l'arrêt anticipé. Pour les modèles mBART, le réglage par défaut est une longueur maximale de 90 tokens, une longueur minimale de 24 tokens et 5 beams. Pour le turc, des réglages spécifiques ont été appliqués afin de produire des résumés plus équilibrés et plus complets: longueur maximale de 84 tokens, longueur minimale de 26 tokens, 6 beams, interdiction de répétition de 4-grammes et pénalité de répétition plus élevée. Pour le modèle mT5, la longueur maximale est de 84 tokens, la longueur minimale de 20 tokens, avec 4 beams et une interdiction de répétition de 2-grammes.

Les résumés produits sont ensuite post-traités. Dans cette étape, la répétition du titre au début du résumé est évitée, les résumés trop proches du titre sont rejetés, les sorties incomplètes ou dégradées sont nettoyées, et un résumé extractif de secours est utilisé en cas de sortie dégénérée. Ainsi, lorsque le modèle échoue, le système ne renvoie pas une réponse vide; il extrait plutôt un court résumé contrôlé à partir du texte source.

4.4 Méthode d'évaluation

4.4.1 Jeu de données d'évaluation et plan des modèles

Dans la chaîne d'évaluation, la partie test du jeu de données `csebuetnlp/xlsum` a été utilisée. Même si le plan du projet contient 15 langues, les langues sans sous-ensemble disponible dans la version publique de XL-Sum ont été exclues de l'évaluation. Ainsi, l'évaluation complète contient 11 langues et 52.219 exemples de test.

Les modèles évalués sont `mbart50_xlsum`, `mbart-xlsum-2` et `mt5-xlsum`. Les modèles BART spécifiques à l’anglais sont définis dans la chaîne d’évaluation, mais le rapport se concentre principalement sur la comparaison des modèles multilingues. Le titre n’a pas été ajouté à l’entrée du modèle pendant l’évaluation; le modèle a produit les résumés uniquement à partir du corps de l’article. Cette décision est cohérente avec le comportement de l’application, où le titre est affiché séparément dans l’interface et le modèle reçoit le corps de l’article comme entrée de résumé.

4.4.2 Métriques classiques et comportementales

Les métriques d’évaluation sont organisées en trois groupes. Le premier groupe contient les métriques classiques de recouvrement avec la référence: ROUGE-1, ROUGE-2, ROUGE-L, BLEU et METEOR-lite. Ces métriques mesurent la similarité entre le résumé produit par le modèle et le résumé humain de référence.

Le deuxième groupe contient les métriques de comportement liées à la source et à la génération. Il comprend `source_coverage`, `source_recall`, `fragment_coverage`, `fragment_density`, `novelty_1gram`, `novelty_2gram`, `repetition_3gram`, `compression_ratio`, `latency_seconds` et `latency_per_1k_tokens`. Ces métriques permettent d’analyser non seulement la similarité avec la référence, mais aussi la fidélité à la source, la tendance à la répétition, le degré d’abstraction, le comportement de compression et le temps d’exécution.

4.4.3 Scores proxy composites

Le troisième groupe correspond aux scores proxy composites conçus dans le cadre du projet. Ces scores ne remplacent pas l’évaluation humaine; ils permettent cependant de comparer les modèles automatiquement et de façon reproductible dans les mêmes conditions. Les cinq scores principaux de capacité sont la cohérence, l’exactitude, la clarté, la pertinence et l’efficacité. Leur moyenne donne le score général de capacité.

$$C_{\text{all}} = \text{mean}(C_{\text{coh}}, C_{\text{acc}}, C_{\text{clar}}, C_{\text{rel}}, C_{\text{eff}}) \quad (2)$$

Dans cette équation, C_{all} représente le score général de capacité. C_{coh} , C_{acc} , C_{clar} , C_{rel} et C_{eff} représentent respectivement la cohérence, l’exactitude, la clarté, la pertinence et l’efficacité. Deux scores de qualité supplémentaires sont utilisés pour la fidélité à la source et la complétude du contenu. `quality_factuality` mesure approximativement la fidélité du résumé au texte source à partir de la couverture de la source et des fragments présents directement dans la source:

$$Q_{\text{fact}} = \text{clip}_{[0,1]}(0.60 \cdot S_{\text{cov}} + 0.40 \cdot F_{\text{cov}}) \quad (3)$$

`quality_completeness` est calculé à partir de la couverture du contenu de référence et de l’alignement de longueur entre le résumé produit et le résumé de référence:

$$A_{\text{len}} = \text{clip}_{[0,1]} \left(1 - \frac{|T_s - T_r|}{\max(T_r, 1)} \right) \quad (4)$$

$$Q_{\text{comp}} = \text{clip}_{[0,1]}(0.70 \cdot R_1 + 0.30 \cdot A_{\text{len}}) \quad (5)$$

Dans ces formules, Q_{fact} représente le score de fidélité à la source, S_{cov} la couverture de la source, F_{cov} la couverture des fragments présents dans la source, A_{len} l’alignement de longueur, T_s la longueur du résumé produit, T_r la longueur du résumé de référence et R_1 la valeur de rappel ROUGE-1. Tous les scores sont bornés dans l’intervalle $[0, 1]$. Ce choix facilite l’interprétation conjointe de métriques ayant des échelles différentes.

4.5 Architecture de l’application web

4.5.1 Approche d’ingestion en arrière-plan

L’architecture de l’application a été conçue pour séparer la génération des résumés du moment de la requête utilisateur. Dans une approche plus directe, les nouvelles pourraient être collectées et résumées au moment de l’appel API. Dans l’architecture actuelle, la collecte des nouvelles et la génération des résumés sont déplacées vers un service d’ingestion




Figure 4.2: Flux de collecte et de génération de résumés en arrière-plan

en arrière-plan. Ainsi, l'appel `GET /api/news` ne lance pas directement un modèle; il retourne les articles et résumés déjà préparés dans la base SQLite.

Le service d'ingestion en arrière-plan fonctionne à intervalles réguliers. Par défaut, une première exécution est lancée automatiquement au démarrage de l'application, puis le processus est répété selon la valeur de `INGEST_INTERVAL_SECONDS`. À chaque exécution, un quota équitable est appliqué entre les langues, et les sources sont traitées en round-robin à l'intérieur de chaque langue. Cette conception évite qu'une seule langue ou une seule source consomme toute la capacité de traitement.

Figure 4.2 présente le flux d'ingestion en arrière-plan de l'application.

4.5.2 Couches de services

L'application est organisée sous forme de couches de services. `NewsService` collecte les nouvelles RSS selon la langue et les filtres choisis. `ArticleService` tente d'extraire le texte principal et l'image à partir du lien de l'article. `SummarizationService` résume le texte nettoyé avec le modèle choisi et applique le post-traitement. `StorageService` stocke les articles, les résumés et les exécutions d'ingestion dans la base SQLite. `FeedService` récupère depuis la base les nouvelles à afficher dans l'interface et appelle le service de tra-

duction si nécessaire. `TranslationService` traduit le titre et le résumé vers la langue cible.

La base de données contient trois tables principales. La table `news_items` stocke le lien de l'article, la source, la langue, le sujet, le pays, la région, le titre, la date de publication, le lien de l'image et le texte de l'article. La table `news_summaries` contient les résumés produits par modèle pour chaque article. La table `ingest_runs` enregistre la configuration, l'état et les statistiques des exécutions d'ingestion en arrière-plan. L'unicité du lien d'article permet d'éviter l'insertion répétée du même article.

4.5.3 API et interface utilisateur

Le principal endpoint de l'application est `GET /api/news`. Il accepte des paramètres comme la langue, la langue de sortie, le sujet, le pays, la région, la source, le modèle, le mot-clé et la limite de résultats. Pour les langues autres que l'anglais, seuls les modèles multilingues sont acceptés. En plus, `GET /api/ingest/status` retourne l'état du scheduler et de la dernière exécution d'ingestion, tandis que `POST /api/ingest/run` place immédiatement une exécution d'ingestion dans la file.

L'interface utilisateur propose des options pour choisir la langue, le type d'actualité, la région, le pays, la source, le mot-clé, le modèle, la langue de sortie et l'affichage des images. Elle affiche le titre de l'article, le résumé, le nom de la source, la date de publication, l'image et le lien vers la source originale. La conservation du lien original montre que le résumé n'est pas présenté comme une source définitive remplaçant l'article, mais comme une aide à la lecture rapide.

4.6 Qualité des sources et gestion des erreurs

Les sources d'actualités réelles ne sont pas aussi régulières que les jeux de données académiques. Certaines sources RSS peuvent être inaccessibles, certaines pages d'articles peuvent ne pas fournir le texte complet, et certaines pages peuvent contenir de la publicité, de la navigation ou des répétitions de titre. Pour cette raison, plusieurs mesures de qualité et de gestion des erreurs ont été mises en place.

Premièrement, lorsque le texte complet ne peut pas être extrait du lien de l'article, le système évite de résumer une entrée vide ou de faible qualité. Deuxièmement, l'étape de nettoyage réduit les répétitions de titre, les phrases de métadonnées et les bruits propres aux sources. Troisièmement, si la génération produit un résumé dégénéré ou presque identique au titre, le système rejette cette sortie et peut utiliser un résumé extractif de secours. Quatrièmement, un script de validation du pool de sources a été préparé afin d'évaluer l'accès RSS, la longueur du corps de l'article, la qualité du texte et la capacité de résumé.

Cette méthode possède certaines limites. Premièrement, le système n'est pas un système de fact-checking indépendant capable de vérifier la vérité externe d'une nouvelle. Les métriques de fidélité à la source et le score `quality_factuality` sont des mesures proxy qui évaluent si le résumé reste proche du texte source; elles ne garantissent pas la véracité de l'information dans le monde réel. Deuxièmement, les sources RSS sont souvent limitées aux nouvelles récentes; la couverture historique du système dépend donc de l'historique fourni par chaque flux. Troisièmement, la performance des modèles multilingues varie selon la langue; un seul score général ne suffit donc pas pour prendre une décision valable pour toutes les langues.

Malgré ces limites, la méthode correspond à l'objectif principal du projet: entraîner des modèles de résumé d'actualités multilingues, les évaluer avec un modèle de comparaison prêt à l'emploi, analyser la qualité des résumés avec des métriques multidimensionnelles et intégrer les modèles dans une application web fonctionnelle fournissant un flux d'actualités réel.

5 APPLICATION NUMERIQUE

Cette partie présente la réalisation numérique du projet. Elle décrit les données utilisées, les modèles entraînés ou intégrés, les choix d’implémentation, la chaîne d’évaluation et les résultats expérimentaux obtenus. L’objectif n’est pas seulement de montrer qu’un modèle peut produire un résumé, mais de vérifier qu’un système complet peut collecter des actualités, extraire le texte utile, générer des résumés multilingues, stocker les résultats et comparer les modèles selon des métriques mesurables.

Le répertoire du projet est organisé autour de trois blocs principaux. Le dossier `models/` contient les modèles locaux et les notebooks d’entraînement. Le dossier `evaluation/` contient les notebooks, rapports, fichiers CSV, fichiers JSONL, classeurs XLSX et figures produits par les évaluations. Le dossier `app/` contient l’application web, les services d’ingestion, les services de stockage, les services de génération de résumés et l’interface utilisateur.

5.1 Jeu de données XL-Sum

Le corpus principal utilisé pour l’évaluation multilingue est `csebuetnlp/xlsum`. XL-Sum est un jeu de données de résumé abstrait d’actualités couvrant plusieurs langues (Hasan et al., 2021). Dans la version utilisée dans ce projet, chaque exemple contient les champs `id`, `url`, `title`, `summary` et `text`. Le champ `text` correspond au corps de l’article, le champ `summary` au résumé humain de référence, et le champ `title` au titre de l’article.

Le plan initial du projet couvre 15 langues: anglais, turc, français, allemand, espagnol, italien, russe, arabe, hindi, chinois simplifié, japonais, coréen, néerlandais, roumain et vietnamien. Cependant, l’analyse locale du corpus montre que quatre sous-ensembles prévus ne sont pas disponibles dans la version publique utilisée: allemand, italien, néerlandais et roumain. Les évaluations finales ont donc été réalisées sur 11 langues exécutables: anglais, turc, français, espagnol, russe, arabe, hindi, chinois simplifié, japonais,

Tableau 5.1: Langues de l'application et couverture XL-Sum dans le projet

Groupe	Langues	Rôle dans le projet
Couvertes par XL-Sum utilisé	anglais, turc, français, espagnol, russe, arabe, hindi, chinois simplifié, japonais, coréen, vietnamien	Ces langues sont présentes dans les sous-ensembles XL-Sum exécutables. Elles sont utilisées pour l'analyse du dataset et pour l'évaluation complète.
Dans le flux applicatif mais hors XL-Sum final	allemand, italien, néerlandais, roumain	Ces langues sont disponibles dans l'application et peuvent être résumées par les modèles multilingues grâce aux capacités pré-entraînées, mais elles ne sont pas incluses dans l'évaluation XL-Sum finale faute de sous-ensembles disponibles localement.

coréen et vietnamien.

Il faut distinguer les langues présentes dans l'application et les langues effectivement couvertes par l'entraînement/évaluation XL-Sum du projet. L'application contient 15 codes de langue et peut envoyer ces langues aux modèles multilingues lorsque le code de langue mBART ou mT5 existe. En revanche, les sous-ensembles XL-Sum utilisés localement pour l'analyse et l'évaluation ne sont disponibles que pour 11 de ces langues. Les langues allemand, italien, néerlandais et roumain restent donc dans le flux applicatif RSS et dans l'interface, mais elles ne sont pas couvertes par les statistiques XL-Sum finales ni par l'évaluation complète du projet.

Le Tableau 5.2 montre que la partie d'entraînement contient 632.038 exemples pour les 11 langues exécutables, tandis que les parties validation et test contiennent chacune 52.219

Tableau 5.2: Répartition globale de XL-Sum dans les sous-ensembles exécutables

Split	Lignes	Articles moyens	Résumés moyens	Ratio résumé/article
Train	632038	816.777	39.228	0.084
Validation	52219	695.923	37.084	0.072
Test	52219	697.318	37.135	0.072




Figure 5.1: Nombre d'exemples XL-Sum par langue et par split

exemples. Les longueurs moyennes indiquent que les articles sont nettement plus longs que les résumés: le ratio moyen `summary/article` est proche de 0.07 sur les splits validation et test. Autrement dit, le résumé de référence représente en moyenne environ 7% de la longueur de l'article.

5.1.1 Répartition linguistique

La distribution par langue est déséquilibrée. L'anglais représente presque la moitié du split d'entraînement, alors que le coréen et le japonais sont beaucoup moins représentés. Ce déséquilibre a motivé l'utilisation d'un lissage par langue dans la deuxième chaîne d'entraînement mBART.

L'analyse du corpus montre aussi un comportement plutôt abstrait. Sur les échantillons analysés, la nouveauté moyenne des bigrammes est d'environ 0.666 sur le train, 0.657 sur la validation et 0.658 sur le test. Cela signifie qu'une grande partie des bigrammes des résumés de référence n'apparaît pas telle quelle dans l'article source. Les modèles doivent donc apprendre à reformuler, pas seulement à extraire des segments du texte.

Tableau 5.3: Nombre d'exemples XL-Sum par langue

Langue	Train	Validation	Test
Anglais	306522	11535	11535
Turc	27176	3397	3397
Français	8697	1086	1086
Espagnol	38110	4763	4763
Russe	62243	7780	7780
Arabe	37519	4689	4689
Hindi	70778	8847	8847
Chinois simplifié	37362	4670	4670
Japonais	7113	889	889
Coréen	4407	550	550
Vietnamien	32111	4013	4013

5.2 Modèles intégrés dans le projet

Le dossier `models/` contient six modèles de génération de résumés ou de traduction. Les modèles `bart_large_cnn`, `bart_base_cnn` et `bart_reuters` sont des modèles BART destinés principalement à l'anglais. Les modèles `mbart50_xlsum` et `mbart-xlsum-2` sont les deux modèles multilingues entraînés dans le cadre du projet. Le modèle `mt5-xlsum` est un modèle mT5 déjà entraîné, utilisé comme référence comparative. Le dossier `mbart-large-50-many-to-many` sert à la traduction optionnelle des titres et résumés lorsque cette couche est activée.

Les deux modèles mBART ont la même architecture sauvegardée: 12 couches encodeur, 12 couches décodeur, 16 têtes d'attention dans chaque bloc, dimension cachée 1024 et vocabulaire de 250.054 tokens. La différence entre ces deux modèles ne vient donc pas de l'architecture, mais des données d'entraînement, des hyperparamètres, de la stratégie de validation et du rééchantillonnage linguistique.

Le modèle `mbart50_xlsum` correspond à la première chaîne d'entraînement. Il part de `facebook/mbart-large-50-many-to-many-mmt`, utilise GEM/xlsum, limite l'entrée à 512 tokens et la cible à 96 tokens. L'entraînement est réalisé pendant 2 epochs avec un




Figure 5.2: Longueur moyenne des articles et des résumés dans le split train

Tableau 5.4: Informations de configuration des principaux modèles

Modèle	Famille	d	Enc.	Dec.	Vocab.
bart_large_cnn	BART-large	1024	12	12	50265
bart_base_cnn	BART-base	768	6	6	50265
bart_reuters	BART-base	768	6	6	50265
mbart50_xlsum	mBART-50	1024	12	12	250054
mbart-xlsum-2	mBART-50	1024	12	12	250054
mt5-xlsum	mT5	768	12	12	250112

taux d'apprentissage de 3×10^{-5} . La taille de batch par appareil est 32 et l'accumulation de gradient est 8. L'évaluation générée est désactivée pendant l'entraînement et le meilleur checkpoint n'est pas sélectionné automatiquement.

Le modèle `mbart-xlsum-2` correspond à la chaîne plus orientée qualité. Il part du même modèle de base, mais utilise `csebuetnlp/xlsum`. La longueur d'entrée reste 512 tokens et la longueur cible passe à 64 tokens. L'entraînement est contrôlé par `max_steps=35000`, avec un taux d'apprentissage de 1×10^{-4} , `warmup_steps=5000`, `adafactor`, `inverse_sqrt`, une taille de batch par appareil de 8, une accumulation de gradient de 4 et une évaluation générée toutes les 5.000 étapes. Le meilleur checkpoint est chargé à la fin selon `eval_rougeL`.

Le lissage linguistique utilisé dans la deuxième chaîne diminue la domination des langues




Figure 5.3: Nouveauté moyenne des bigrammes par langue et par split

très fréquentes. Si n_l est le nombre d'exemples d'une langue l et L l'ensemble des langues, la probabilité de rééchantillonnage est:

$$p_l = \frac{n_l^\alpha}{\sum_{j \in L} n_j^\alpha}, \quad \alpha = 0.5. \quad (1)$$

Avec $\alpha = 1$, la distribution suit directement les tailles originales des langues. Avec $\alpha = 0.5$, les grandes langues restent importantes, mais les langues plus petites deviennent plus visibles pendant l'entraînement.

Tableau 5.5: Comparaison des deux chaînes d'entraînement mBART

Élément	mbart50_xlsum	mbart-xlsum-2
Modèle de base	facebook/mbart-large-50-many-to-many-mmt	facebook/mbart-large-50-many-to-many-mmt
Jeu de données	GEM/xlsum	csebuetnlp/xlsum
Longueur source / cible	512 / 96 tokens	512 / 64 tokens
Durée	2 epochs	35.000 steps
Learning rate	3×10^{-5}	1×10^{-4}
Batch effectif	32×8	8×4
Optimisation	Paramètres Trainer par défaut	adafactor + inverse_sqrt
Validation	Désactivée pendant l'entraînement	Toutes les 5.000 étapes
Sélection du check-point	Non	Oui, selon ROUGE-L
Équilibrage des langues	Mélange standard	Lissage avec $\alpha = 0.5$

5.3 Architecture de l'application

L'application web se trouve dans le dossier `app/`. Elle expose une interface et une API permettant de consulter des actualités résumées. Le système ne génère pas les résumés au moment exact de chaque requête utilisateur. La génération est déplacée dans un processus d'ingestion en arrière-plan. Cette architecture réduit la latence perçue par l'utilisateur et permet de stocker plusieurs résumés par article et par modèle.

Le flux numérique est le suivant. Le scheduler lance périodiquement l'ingestion. Le service de nouvelles collecte les entrées RSS selon les filtres de langue, source, sujet, pays et région. Le service d'article tente d'ouvrir le lien original, d'extraire le corps de l'article et de nettoyer le texte. Le service de résumé appelle le modèle choisi, applique un post-traitement, puis utilise un résumé extractif de secours si la sortie est vide ou dégénérée. Enfin, le service de stockage écrit les articles et les résumés dans SQLite.

5.3.1 Paramètres applicatifs

Les paramètres principaux de l'application sont définis dans `app/core.py` et dans les variables d'environnement. Par défaut, le modèle principal est `mbart50_xlsum`. La limite de texte envoyée au modèle est `MAX_INPUT_CHARS=3500`. La tokenisation limite l'entrée à 1024 tokens. Le nombre maximum de tokens de résumé par défaut est `SUMMARY_MAX_TOKENS=96`.

Pour les modèles mBART, l'application configure le code de langue mBART associé à la langue source, puis force le token de début de génération correspondant. Les paramètres de génération mBART par défaut sont: longueur maximale 90, longueur minimale 24, 5 beams et pénalité de longueur 1.1. Pour le turc, le système utilise un réglage spécifique: longueur maximale 84, longueur minimale 26, 6 beams, `no_repeat_ngram_size=4` et pénalité de répétition 1.2. Pour `mt5-xlsum`, la longueur maximale est 84, la longueur minimale 20 et le nombre de beams 4.

La base SQLite contient trois tables principales. `news_items` stocke les articles, les métadonnées, la langue, la source et le texte extrait. `news_summaries` stocke le résumé produit pour un couple article-modèle-langue, avec une contrainte d'unicité sur `news_item_id`, `model_key` et `language_key`. `ingest_runs` garde l'historique des exécutions d'ingestion, leur configuration, leurs statistiques et les erreurs éventuelles.

5.4 Pipeline d'évaluation

L'évaluation finale est produite par le notebook `evaluation/pipelines/xlsum_model_evaluation.py`. La configuration sauvegardée dans `evaluation/xlsum_eval_full/run_config.json` indique que le split utilisé est `test`, que les titres ne sont pas ajoutés à l'entrée du modèle, que la taille de batch est 8, que l'entrée est limitée à 512 tokens et que l'exécution utilise CUDA avec FP16 lorsque c'est disponible.

Les modèles évalués dans le rapport final sont `mbart50_xlsum`, `mbart-xlsum-2` et `mt5-xlsum`. Les modèles BART anglais sont définis dans la pipeline, mais le rapport numérique final se concentre sur les modèles multilingues, car le scénario principal du projet est le résumé

d’actualités dans plusieurs langues.

La pipeline bloque explicitement l’utilisation du `split train` pour éviter une fuite de données. Elle produit notamment `detailed_metrics.csv`, `detailed_predictions.jsonl`, `model_language_summary.csv`, `model_overall_macro_summary.csv`, `xlsum_evaluation_report.md` et plusieurs figures.

5.4.1 Formules des métriques classiques

Soit r le résumé de référence et $\hat{y}$ le résumé généré. Pour ROUGE- N , on note $G_N(x)$ le multiensemble des N -grammes du texte x . La précision, le rappel et la F-mesure sont:

$$P_N = \frac{|G_N(\hat{y}) \cap G_N(r)|}{|G_N(\hat{y})|}, \quad (2)$$

$$R_N = \frac{|G_N(\hat{y}) \cap G_N(r)|}{|G_N(r)|}, \quad (3)$$

$$F_N = \frac{2P_N R_N}{P_N + R_N}. \quad (4)$$

ROUGE-L remplace le recouvrement de N -grammes par la longueur de la plus longue sous-séquence commune, notée $\text{LCS}(\hat{y}, r)$:

$$P_L = \frac{\text{LCS}(\hat{y}, r)}{|\hat{y}|}, \quad (5)$$

$$R_L = \frac{\text{LCS}(\hat{y}, r)}{|r|}, \quad (6)$$

$$F_L = \frac{2P_L R_L}{P_L + R_L}. \quad (7)$$

BLEU est calculé avec `sacrebleu` au niveau phrase, sans retokenisation supplémentaire et avec lissage exponentiel. Sa forme générale est:

$$\text{BLEU} = \text{BP} \cdot \exp \left(\sum_{n=1}^4 w_n \log p_n \right), \quad (8)$$

où p_n représente la précision modifiée des n -grammes, w_n les poids des ordres de n -grammes et BP la pénalité de brièveté.

La métrique METEOR-lite implémentée dans la pipeline utilise les correspondances exactes de tokens. Si m est le nombre de tokens appariés, $P_m = m/|\hat{y}|$ et $R_m = m/|r|$, alors:

$$F_{\text{mtor}} = \frac{10P_m R_m}{R_m + 9P_m}, \quad (9)$$

$$\text{Penalty} = 0.5 \left(\frac{\text{chunks}}{m} \right)^3, \quad (10)$$

$$\text{METEOR-lite} = F_{\text{mtor}}(1 - \text{Penalty}). \quad (11)$$

5.4.2 Métriques source et comportement

Les métriques classiques sont complétées par des métriques liées à la source et au comportement de génération. La couverture source mesure la part du vocabulaire du résumé qui est présente dans l'article source:

$$S_{\text{cov}} = \frac{|V(\hat{y}) \cap V(x)|}{|V(\hat{y})|}. \quad (12)$$

Le rappel source mesure la part du vocabulaire de l'article qui est reprise dans le résumé:

$$S_{\text{rec}} = \frac{|V(\hat{y}) \cap V(x)|}{|V(x)|}. \quad (13)$$

Le taux de compression utilisé dans l'évaluation est le rapport entre la longueur source et la longueur générée:

$$\text{compression} = \frac{|x|}{|\hat{y}|}. \quad (14)$$

La latence est aussi normalisée par 1.000 tokens source:

$$\text{latency}_{1k} = \frac{\text{latency}_{sec}}{\max(|x|/1000, 10^{-6})}. \quad (15)$$

La répétition est mesurée par le taux de n -grammes répétés dans le résumé généré. Dans la pipeline, la valeur utilisée dans les scores composites est surtout `repetition_3gram`:

$$\text{rep}_n = 1 - \frac{|\text{unique}(G_n(\hat{y}))|}{|G_n(\hat{y})|}. \quad (16)$$

La nouveauté mesure la part des n -grammes du résumé qui ne sont pas présents dans l'article source. Elle sert à observer le degré d'abstraction du résumé:

$$\text{novelty}_n = 1 - \frac{|\{g \in G_n(\hat{y}) : g \in G_n(x)\}|}{|G_n(\hat{y})|}. \quad (17)$$

Les fragments extractifs sont les séquences de tokens du résumé qui apparaissent aussi dans la source. Si F est l'ensemble des longueurs de fragments trouvés par l'algorithme de correspondance et si l_f est la longueur du fragment f , alors:

$$F_{\text{cov}} = \frac{\sum_{f \in F} l_f}{|\hat{y}|}, \quad (18)$$

$$F_{\text{dens}} = \frac{\sum_{f \in F} l_f^2}{|\hat{y}|}. \quad (19)$$

La composante de lisibilité dépend de la langue. Pour l'anglais, la pipeline utilise le score de Flesch, normalisé dans $[0, 1]$:

$$R_{\text{read}} = \text{clip}_{[0,1]} \left(\frac{\text{Flesch}(\hat{y}) + 20}{120} \right). \quad (20)$$

Pour les autres langues, la pipeline utilise un score heuristique de longueur moyenne de phrase. Si $\bar{s}$ est la longueur moyenne des phrases, l'intervalle idéal est $[12, 45]$ pour le chinois, le japonais et le coréen, et $[8, 25]$ pour les autres langues:

$$I_{\text{sent}} = \begin{cases} 0, & \bar{s} \leq 0, \\ \text{clip}_{[0,1]}(\bar{s}/a), & 0 < \bar{s} < a, \\ 1, & a \leq \bar{s} \leq b, \\ \text{clip}_{[0,1]}(1 - (\bar{s} - b)/b), & \bar{s} > b. \end{cases} \quad (21)$$

Dans cette formule, $(a, b) = (12, 45)$ pour les langues CJK et $(a, b) = (8, 25)$ pour les autres langues. Pour les langues non anglaises, R_{read} est remplacé par I_{sent} .

5.4.3 Scores proxy composites

Les scores proxy composites sont bornés dans l'intervalle $[0, 1]$ avec l'opérateur $\text{clip}_{[0,1]}$. Les poids ont été choisis de manière heuristique selon une logique de signal principal et de correction secondaire: le signal le plus directement lié à la dimension mesurée reçoit le poids dominant, tandis que les autres signaux corrigent les cas limites. Ces scores ne sont donc pas des métriques humaines apprises, mais des indicateurs automatiques reproductibles pour comparer les modèles dans les mêmes conditions.

La cohérence combine la stabilité des longueurs de phrases, le faible taux de répétition et une longueur de phrase idéale. Le poids principal est donné à la régularité des longueurs de phrases, car elle mesure directement la stabilité structurelle du résumé:

$$\begin{aligned} C_{\text{coh}} = & \text{clip}_{[0,1]}(0.50 \cdot \text{clip}_{[0,1]}(1 - \sigma_{\text{sent}}/20) \\ & + 0.30 \cdot (1 - \text{rep}_{3g}) \\ & + 0.20 \cdot I_{\text{sent}}). \end{aligned} \quad (22)$$

L'exactitude combine l'accord avec la référence et la couverture de la source. Le poids 0.70 est donné à l'accord avec le résumé humain, car la référence reste le signal principal de correction; le poids 0.30 ajoute une contrainte de rattachement au texte source:

$$A_{\text{ref}} = \text{mean}(\text{ROUGE-L}, \text{BLEU}, \text{METEOR-lite}), \quad (23)$$

$$C_{\text{acc}} = \text{clip}_{[0,1]}(0.70 \cdot A_{\text{ref}} + 0.30 \cdot S_{\text{cov}}). \quad (24)$$

La clarté combine la lisibilité et l'absence de répétition. La lisibilité reçoit le poids dominant, car elle mesure directement la facilité de lecture, tandis que la répétition corrige les sorties artificiellement lisibles mais redondantes:

$$C_{\text{clar}} = \text{clip}_{[0,1]}(0.70 \cdot R_{\text{read}} + 0.30 \cdot (1 - \text{rep}_{3g})). \quad (25)$$

La pertinence combine le rappel ROUGE-1 et le rappel source. Le rappel ROUGE-1 est dominant parce qu'il mesure la couverture du contenu attendu dans la référence; le rappel source ajoute une indication de couverture du document original:

$$C_{\text{rel}} = \text{clip}_{[0,1]}(0.70 \cdot R_1 + 0.30 \cdot S_{\text{rec}}). \quad (26)$$

L'efficacité combine la vitesse et la compression. La vitesse normalisée reçoit le poids 0.60, car l'application vise un usage interactif; la compression reçoit le poids 0.40, car un résumé rapide mais trop long serait peu utile:

$$L_{\text{score}} = \frac{1}{1 + \text{latency}_{1k}}, \quad (27)$$

$$K_{\text{score}} = \text{clip}_{[0,1]} \left(\frac{\text{compression} - 2}{18} \right), \quad (28)$$

$$C_{\text{eff}} = \text{clip}_{[0,1]}(0.60 \cdot L_{\text{score}} + 0.40 \cdot K_{\text{score}}). \quad (29)$$

Le score global de capacité est la moyenne de ces cinq dimensions:

$$C_{\text{all}} = \text{mean}(C_{\text{coh}}, C_{\text{acc}}, C_{\text{clar}}, C_{\text{rel}}, C_{\text{eff}}). \quad (30)$$

Deux scores de qualité supplémentaires sont utilisés. La fidélité à la source combine la couverture source et la couverture des fragments extraits. La couverture source reçoit le poids principal parce qu'elle pénalise les mots absents de l'article, tandis que les fragments extraits renforcent l'indication de rattachement direct au texte:

$$Q_{\text{fact}} = \text{clip}_{[0,1]}(0.60 \cdot S_{\text{cov}} + 0.40 \cdot F_{\text{cov}}). \quad (31)$$

La complétude combine le rappel ROUGE-1 et l'alignement de longueur avec le résumé de référence. Le rappel ROUGE-1 mesure la présence du contenu attendu; l'alignement de longueur évite de favoriser des résumés trop courts ou trop longs:

$$A_{\text{len}} = \text{clip}_{[0,1]} \left(1 - \frac{||\hat{y}| - |r||}{\max(|r|, 1)} \right), \quad (32)$$

$$Q_{\text{comp}} = \text{clip}_{[0,1]}(0.70 \cdot R_1 + 0.30 \cdot A_{\text{len}}). \quad (33)$$

6 ANALYSE DES RESULTATS OBTENUS ET DISCUSSIONS

Cette partie analyse les résultats expérimentaux obtenus dans l'évaluation complète des modèles de résumé multilingue. Les résultats utilisés proviennent du répertoire `evaluation/xlsum_eval_full`. L'évaluation a été réalisée sur le split test de `csebuetnlp/xlsum`, avec 52.219 exemples répartis sur 11 langues exécutables: arabe, anglais, espagnol, français, hindi, japonais, coréen, russe, turc, vietnamien et chinois simplifié. Les langues allemand, italien, néerlandais et roumain, prévues dans le plan initial, n'ont pas été évaluées car les sous-ensembles publics correspondants n'étaient pas disponibles dans la version locale de XL-Sum.

Il faut donc distinguer la couverture expérimentale et la couverture applicative. Les données d'entraînement et d'évaluation disponibles dans XL-Sum couvrent 11 langues dans cette exécution, mais l'application finale conserve un support de résumé pour 15 langues. Les quatre langues non évaluées quantitativement, c'est-à-dire l'allemand, l'italien, le néerlandais et le roumain, peuvent encore être traitées dans le flux applicatif par les modèles multilingues lorsque le code de langue et la tokenisation du modèle le permettent. En revanche, aucune conclusion numérique solide n'est tirée pour ces quatre langues, car elles ne disposent pas ici d'un split XL-Sum comparable.

Trois modèles sont comparés. Les modèles `mbart50_xlsum` et `mbart-xlsum-2` sont les deux modèles mBART entraînés dans le cadre du projet. Le modèle `mt5-xlsum` est utilisé comme modèle de comparaison prêt à l'emploi. Il ne doit donc pas être interprété comme une sortie directe de l'entraînement du projet, mais comme une référence forte pour situer la performance des modèles mBART.

Les métriques interprétées dans cette section couvrent trois familles. La première regroupe les métriques classiques de recouvrement avec le résumé de référence, notamment ROUGE-L, BLEU et METEOR-lite. La deuxième regroupe les métriques de comportement, comme la couverture de la source, le taux de compression, la nouveauté et la latence. La troisième regroupe les scores proxy composites définis dans la pipeline d'évaluation: cohérence, exactitude, clarté, pertinence, efficacité et score global de ca-

Tableau 6.1: Synthèse macro des résultats sur XL-Sum test

Modèle	Cap.	R-L	BLEU	METEOR	Fact.	Lat.
mt5-xlsum	0.6631	0.3010	0.1310	0.3195	0.8522	0.2552
mbart50-xlsum	0.6578	0.2785	0.1202	0.3157	0.8522	0.1917
mbart-xlsum-2	0.6570	0.2792	0.1228	0.3181	0.8249	0.1840

pacité. Ces scores automatiques ne remplacent pas une évaluation humaine, mais ils permettent une comparaison reproductible des modèles dans les mêmes conditions expérimentales.

Le Tableau 6.1 montre que les trois modèles restent proches en score global de capacité. mt5-xlsum obtient la meilleure moyenne globale, avec 0.6631. Les deux modèles mBART suivent avec 0.6578 et 0.6570. L'écart absolu entre le meilleur modèle et le meilleur modèle entraîné dans le projet est donc d'environ 0.0053, ce qui indique une proximité globale malgré des profils de comportement différents.

6.1 Classement global des modèles

La Figure 6.1 résume le rang de chaque modèle selon les principales métriques. Elle confirme que le classement n'est pas uniforme: mt5-xlsum domine les métriques classiques de similarité avec la référence, tandis que les modèles mBART sont plus compétitifs sur l'efficacité et certains indicateurs de comportement.

Le principal avantage de mt5-xlsum concerne la similarité avec les résumés humains. Il obtient les meilleures valeurs en ROUGE-L, BLEU et METEOR-lite. Cela signifie que ses sorties recouvrent davantage les formulations et le contenu lexical des références XL-Sum. Ce résultat est cohérent avec son rôle de modèle de référence déjà adapté à XL-Sum.

Les deux modèles mBART présentent un profil différent. mbart50-xlsum atteint un score global très proche de mt5-xlsum tout en étant plus rapide. Il conserve aussi une forte fidélité à la source: son score de factualité est pratiquement identique à celui de mt5-




Figure 6.1: Classement global des modèles selon les métriques principales

xlsum. mbart-xlsum-2 est le modèle le plus rapide en moyenne et obtient la meilleure complétude automatique, mais il perd une partie de la couverture source. Son comportement est donc plus abstractive, avec un gain léger en BLEU, METEOR-lite et complétude par rapport à mbart50-xlsum, mais avec une baisse de l’ancrage direct dans le texte source.

La moyenne globale doit cependant être complétée par une lecture par langue. Le Tableau 6.2 montre que mt5-xlsum est premier dans 7 langues, tandis que mbart50-xlsum est premier dans 4 langues. mbart-xlsum-2 n’est pas premier selon le score global de capacité, mais il reste proche du meilleur modèle dans plusieurs langues, notamment en hindi, vietnamien et chinois simplifié.

Tableau 6.2: Meilleur modèle par langue selon le score global de capacité

Langue	Meilleur	Cap.	Deuxième	Écart
arabe	mbart50	0.6403	mt5	0.0021
anglais	mbart50	0.6255	mbart-2	0.0022
espagnol	mt5	0.6725	mbart50	0.0026
français	mbart50	0.6463	mt5	0.0005
hindi	mt5	0.6544	mbart-2	0.0041
japonais	mt5	0.6977	mbart50	0.0106
coréen	mt5	0.7334	mbart50	0.0095
russe	mbart50	0.6385	mbart-2	0.0028
turc	mt5	0.6278	mbart50	0.0092
vietnamien	mt5	0.6524	mbart-2	0.0043
chinois simplifié	mt5	0.7134	mbart-2	0.0158

Cette table montre que les écarts sont parfois très faibles. En français, par exemple, mbart50 devance mt5 de seulement 0.0005. En anglais, les trois modèles sont également très proches. À l'inverse, l'avantage de mt5 est plus net en chinois simplifié, japonais, coréen et turc. Pour cette raison, le choix du modèle ne doit pas être fait uniquement à partir de la moyenne macro, mais aussi selon la langue cible.

La Figure 6.2 illustre le compromis entre latence moyenne et capacité globale. Le point le plus haut correspond à mt5-xlsum, mais il est aussi plus lent. Les deux mBART sont situés plus à gauche, ce qui correspond à un temps moyen plus faible. Ce résultat est important pour l'application, car la génération des résumés doit rester exploitable dans un flux d'actualités multilingue.

L'interprétation numérique confirme donc que le gain de qualité de mt5-xlsum est faible par rapport à son coût temporel. Par rapport à mt5-xlsum, mbart50-xlsum réduit la latence d'environ 24.9% pour une baisse absolue de capacité de seulement 0.0053. mbart-xlsum-2 réduit la latence d'environ 27.9%, avec une baisse absolue de capacité de 0.0061. Ainsi, si l'objectif principal est la meilleure moyenne de capacité, mt5-xlsum reste pre-




Figure 6.2: Compromis entre latence moyenne et capacité globale

mier; si l'objectif est un compromis utilisable dans une application interactive, les deux modèles mBART sont plus avantageux, surtout mbart50_xlsum qui garde presque le même score global avec une latence plus faible.

6.2 Compression, complétude et abstraction

Le taux de compression et la complétude montrent un autre compromis. mt5-xlsum produit en moyenne des résumés plus courts: son taux de compression moyen est 27.13, contre 23.25 pour mbart50_xlsum et 23.10 pour mbart-xlsum-2. En revanche, les deux modèles mBART obtiennent une complétude légèrement supérieure: 0.4525 pour mbart50_xlsum et 0.4576 pour mbart-xlsum-2, contre 0.4489 pour mt5-xlsum.

La Figure 6.3 montre que la compression plus forte ne conduit pas automatiquement à une meilleure complétude. mt5-xlsum est plus concis, mais les modèles mBART gardent légèrement plus de contenu selon le score de complétude. Dans le contexte du projet,




Figure 6.3: Compromis entre taux de compression et complétude automatique

ce résultat est utile: un résumé d'actualité ne doit pas seulement être court, il doit aussi conserver les informations essentielles de l'article.

Cependant, la position verticale montre l'effet inverse: `mt5-xlsum` obtient une complétude de 0.4489, alors que `mbart50_xlsum` atteint 0.4525 et `mbart-xlsum-2` 0.4576. Autrement dit, le modèle le plus compressif n'est pas celui qui conserve le plus de contenu selon cette métrique. La différence est faible en valeur absolue, mais elle est importante pour l'interprétation: `mt5-xlsum` privilégie la concision, tandis que les modèles mBART, surtout `mbart-xlsum-2`, gardent un peu plus d'information. Dans le contexte du projet, ce résultat est utile: un résumé d'actualité ne doit pas seulement être court, il doit aussi conserver les informations essentielles de l'article.

La différence entre les deux mBART est également significative. `mbart-xlsum-2` a été entraîné avec une cible plus courte et une stratégie de validation plus orientée qualité. Pourtant, il produit en moyenne un nombre de tokens proche de `mbart50_xlsum` et obtient une meilleure complétude. En parallèle, sa nouveauté 2-grammes atteint 0.4712,




Figure 6.4: Latence moyenne par langue et par modèle

contre 0.4229 pour `mbart50_xlsum`. Cela indique que le deuxième modèle reformule davantage. Cette abstraction peut améliorer la qualité perçue lorsque la reformulation reste correcte, mais elle augmente aussi le risque de s'éloigner de la source.

6.3 Analyse de la latence par langue

Les cartes thermiques de latence permettent d'observer si le coût de génération est uniforme selon les langues. La Figure 6.4 présente la latence moyenne en secondes pour chaque couple langue-modèle, tandis que la Figure 6.5 normalise cette valeur par 1.000 tokens source.

La latence brute dépend à la fois du modèle, de la langue et de la longueur moyenne des




Figure 6.5: Latence moyenne normalisée par 1.000 tokens source

articles. Les langues comme le japonais, le coréen et le chinois ont des textes sources plus longs dans le split test, ce qui peut augmenter le temps absolu de génération. La normalisation par 1.000 tokens permet donc de mieux comparer l'efficacité propre du modèle. Dans les deux vues, mbart-xlsu_m-2 et mbart50_xlsu_m restent généralement plus rapides que mt5-xlsu_m.

Cette différence se voit aussi dans la distribution cumulative de la latence. La Figure 6.6 montre que les courbes des modèles mBART sont déplacées vers les temps plus faibles. Au niveau des exemples, le modèle le plus rapide est mbart-xlsu_m-2 dans 51.4% des cas et mbart50_xlsu_m dans 47.2% des cas. mt5-xlsu_m n'est le plus rapide que dans 1.4% des cas.




Figure 6.6: Distribution cumulative empirique de la latence

Pour l’application web, cette observation justifie l’utilisation d’une génération en arrière-plan et d’un stockage des résumés en base. Même si les temps moyens semblent faibles dans l’environnement d’évaluation, la multiplication par le nombre d’articles, de langues et de modèles rend la latence importante à l’échelle du système.

6.4 Relations entre les métriques

La Figure 6.7 présente les corrélations entre les métriques numériques. Cette figure aide à comprendre pourquoi un modèle peut être premier selon une métrique et moins bon selon une autre. Les métriques classiques de recouvrement sont naturellement liées entre elles, car elles mesurent toutes une forme de proximité avec le résumé de référence. En revanche, les métriques de source, de nouveauté, de compression et de latence capturent des comportements différents.

Cette lecture explique aussi l’écart entre les deux variantes mBART. Le premier modèle est plus proche de la source: il a une couverture source moyenne de 0.8481 et une factualité automatique de 0.8522. Le second est plus abstrait: sa nouveauté 2-grammes monte à 0.4712, mais sa couverture source descend à 0.8203. Ainsi, `mbart-xlsup-2` reformule




Figure 6.7: Corrélation entre les métriques d'évaluation

L'analyse des corrélations confirme qu'il ne faut pas choisir le modèle uniquement avec ROUGE-L. Un modèle peut obtenir une meilleure similarité avec la référence tout en étant plus lent ou moins avantageux pour certaines contraintes applicatives. À l'inverse, un modèle plus rapide peut perdre quelques points de similarité lexicale sans devenir inutilisable. La sélection finale doit donc dépendre du scénario: qualité textuelle maximale, fidélité à la source, vitesse, ou compromis entre ces dimensions.




Figure 6.8: Taux de victoire exemple par exemple selon les métriques

davantage, ce qui améliore certaines métriques de complétude et de recouvrement, mais diminue le signal de rattachement direct à l'article.

Les moyennes macro sont utiles, mais elles peuvent masquer des variations au niveau des exemples individuels. La Figure 6.8 présente les taux de victoire exemple par exemple selon plusieurs métriques. Elle montre que la domination de mt5-xlsum dans les métriques classiques n'est pas absolue, même si elle est nette.

Le Tableau 6.3 montre que mt5-xlsum gagne le plus souvent en ROUGE-L et BLEU. Cependant, les deux mBART gagnent très majoritairement en latence et en efficacité. mbart-xlsum-2 obtient aussi le meilleur taux de victoire en complétude, avec 36.6%. Cette analyse exemple par exemple confirme l'idée d'un compromis: mt5-xlsum est le plus fort pour la proximité au résumé humain, mais les modèles mBART sont plus pratiques lorsque le coût de génération et la couverture utile sont prioritaires.

Tableau 6.3: Taux de victoire exemple par exemple dans l'évaluation complète

Métrique	mt5	mbart50	mbart-2
Capacité globale	35.4%	33.7%	30.9%
ROUGE-L	40.8%	28.7%	30.5%
BLEU	37.0%	30.3%	32.7%
METEOR-lite	34.1%	32.3%	33.6%
Efficacité	14.2%	42.4%	43.3%
Complétude	30.1%	33.3%	36.6%
Latence minimale	1.4%	47.2%	51.4%

6.5 Discussion sur le choix du modèle

Les résultats conduisent à trois conclusions principales. Premièrement, `mt5-xlsum` est le meilleur modèle si le critère principal est la similarité automatique avec les résumés de référence. Il est premier en ROUGE-L, BLEU, METEOR-lite, cohérence, exactitude et clarté. Il constitue donc une référence solide pour l'évaluation du projet.

Deuxièmement, `mbart50-xlsum` est le modèle mBART le plus équilibré pour une utilisation applicative prudente. Son score global est très proche de celui de `mt5-xlsum`, sa latence est plus faible, et sa fidélité à la source reste très élevée. Dans un système de résumé d'actualités, cette caractéristique est importante parce qu'un résumé fluide mais trop éloigné de l'article peut produire une information trompeuse. Le choix de `mbart50-xlsum` comme modèle par défaut dans l'application est donc défendable si l'objectif est de privilégier la stabilité et l'ancrage source.

Troisièmement, `mbart-xlsum-2` est intéressant lorsque l'on cherche un modèle plus rapide et plus abstractive. Il obtient la meilleure efficacité, la meilleure complétude automatique et la latence moyenne la plus basse. Cependant, sa baisse de `quality_factuality` et de `source_coverage` indique qu'il doit être utilisé avec attention pour les articles sensibles ou factuels.

Le Tableau 6.4 résume cette interprétation pratique des trois modèles.

Tableau 6.4: Interprétation pratique des modèles

Modèle	Point fort principal	Usage recommandé
mt5-xlsum	Meilleure similarité avec les résumés de référence	Évaluation comparative et génération lorsque la qualité textuelle automatique est prioritaire.
mbart50-xlsum	Bon compromis entre capacité, vitesse et fidélité à la source	Modèle par défaut prudent pour l'application d'actualités multilingues.
mbart-xlsum-2	Meilleure vitesse et meilleure complétude automatique	Scénario où la latence, la couverture utile et la reformulation sont prioritaires.

6.6 Limites de l'évaluation

Les résultats doivent être interprétés avec plusieurs limites. D'abord, les scores de cohérence, exactitude, clarté, pertinence, efficacité, factualité et complétude sont des proxys automatiques. Ils sont utiles pour comparer les modèles dans une même pipeline, mais ils ne prouvent pas à eux seuls la qualité humaine ni la véracité factuelle des résumés.

Ensuite, l'évaluation est basée sur XL-Sum test. Ce corpus est adapté au résumé d'actualités, mais il ne couvre pas toute la diversité des flux RSS réels utilisés dans l'application. Les articles collectés en production peuvent être plus bruyants, plus courts, plus longs, partiellement extraits ou structurés différemment. Les performances observées sur XL-Sum ne garantissent donc pas exactement le même comportement dans l'application.

Enfin, quatre langues du plan initial n'ont pas pu être évaluées: allemand, italien, néerlandais et roumain. Elles restent présentes dans l'application, mais l'absence de sous-ensemble XL-Sum exécutable empêche une conclusion quantitative solide pour ces langues. Une prochaine étape serait de construire un jeu de test local pour ces langues, ou d'utiliser un autre corpus multilingue compatible avec la tâche de résumé.

6.7 Conclusion de l'analyse

L'évaluation complète montre que les modèles entraînés dans le projet sont compétitifs face à une référence mT5 déjà spécialisée. `mt5-xlsum` reste le meilleur modèle en moyenne pour les métriques classiques et le score global, mais l'écart avec `mbart50-xlsum` est faible. Les modèles mBART apportent surtout un avantage applicatif: ils sont plus rapides et offrent un meilleur compromis entre coût de génération, complétude et fidélité à la source.

Pour une utilisation finale dans le système de résumé d'actualités, le choix le plus cohérent est donc de ne pas résumer la performance par un seul score. `mt5-xlsum` doit rester une référence de qualité, `mbart50-xlsum` est le candidat le plus prudent pour le mode par défaut, et `mbart-xlsum-2` peut être proposé comme alternative plus rapide et plus abstractive. Cette lecture par compromis correspond mieux aux contraintes d'une application réelle qu'un classement fondé uniquement sur ROUGE-L ou BLEU.

7 CONCLUSIONS ET PERSPECTIVES

7.1 Bilan général du projet

Ce projet avait pour objectif de concevoir, évaluer et intégrer un système de résumé automatique d'actualités multilingues. Le travail réalisé ne s'est pas limité à l'entraînement d'un modèle de génération de texte. Il a réuni plusieurs dimensions complémentaires: l'étude des modèles de résumé, l'entraînement de modèles mBART, l'utilisation d'un modèle mT5 prêt à l'emploi comme référence externe, la construction d'une évaluation multidimensionnelle et le développement d'une application web capable de collecter, traiter, résumer et afficher des actualités provenant de flux RSS réels.

La problématique initiale était de savoir comment évaluer des modèles de résumé multilingue selon des critères plus larges que la simple similarité lexicale avec une référence, puis comment utiliser ces modèles dans un système applicatif. Les chapitres précédents ont montré que cette question demande une approche de bout en bout. Un bon modèle de résumé doit produire un texte court et lisible, mais il doit aussi rester fidèle à la source, éviter les répétitions, couvrir les informations importantes et fonctionner avec une latence compatible avec un flux d'actualités.

Le système final répond à cette problématique par une architecture en plusieurs couches. Les données académiques, principalement XL-Sum, ont été utilisées pour entraîner et évaluer les modèles. Les modèles mBART entraînés dans le cadre du projet ont ensuite été comparés avec le modèle mt5-xlsum. Enfin, l'application Flask a permis d'intégrer ces modèles dans un scénario pratique, avec collecte RSS, extraction du corps des articles, nettoyage, génération de résumés, stockage SQLite, ingestion en arrière-plan et interface filtrable.

7.2 Synthèse des résultats obtenus

L'évaluation complète a été réalisée sur le split test de csebuetnlp/xlsum, avec 52.219 exemples répartis sur 11 langues exécutables. Les langues allemand, italien, néerlandais

et roumain étaient prévues dans le plan applicatif, mais elles n’ont pas été évaluées quantitativement car les sous-ensembles publics correspondants n’étaient pas disponibles dans la version locale de XL-Sum. Cette distinction est importante: l’application conserve un support multilingue plus large, mais les conclusions numériques solides concernent les 11 langues effectivement évaluées.

Les résultats montrent que les trois modèles comparés sont proches en score global de capacité. Le modèle `mt5-xlsum` obtient la meilleure moyenne globale, avec un score `capability_overall` de 0.6631. Le modèle `mbart50-xlsum`, entraîné dans le cadre du projet, atteint 0.6578, et `mbart-xlsum-2` atteint 0.6570. L’écart entre le meilleur modèle et le meilleur modèle entraîné dans le projet reste donc faible, ce qui montre que les modèles mBART développés sont compétitifs face à une référence mT5 déjà spécialisée.

La comparaison montre cependant que les modèles n’ont pas le même profil. `mt5-xlsum` est le plus fort pour les métriques classiques de similarité avec les résumés humains, notamment ROUGE-L, BLEU et METEOR-lite. Ce résultat est cohérent avec son rôle de modèle de comparaison déjà entraîné pour le résumé multilingue. À l’inverse, les deux modèles mBART offrent un avantage applicatif clair sur la latence et l’efficacité. `mbart50-xlsum` représente le compromis le plus prudent entre capacité globale, vitesse et fidélité à la source. `mbart-xlsum-2` est le plus rapide en moyenne et obtient une meilleure complétude automatique, mais il est aussi plus abstractive et moins directement ancré dans le texte source.

Ces résultats confirment que le choix du modèle ne doit pas être réduit à un classement unique. Si l’objectif principal est la proximité avec les résumés de référence, `mt5-xlsum` constitue le meilleur choix. Si l’objectif est une intégration applicative stable et plus rapide, `mbart50-xlsum` est un candidat solide comme modèle par défaut. Si la priorité est la vitesse et une reformulation plus forte, `mbart-xlsum-2` peut être utilisé comme alternative, avec une attention particulière aux articles sensibles du point de vue factuel.

7.3 Apports du travail

Le premier apport du projet est la mise en place d'une chaîne complète pour le résumé d'actualités multilingues. Le travail couvre l'analyse du problème, la revue des approches existantes, l'entraînement de modèles mBART, l'évaluation expérimentale et l'intégration dans une application web. Cette continuité entre recherche expérimentale et implémentation logicielle donne au projet une valeur pratique: les modèles ne sont pas seulement comparés sur un corpus fixe, ils sont aussi utilisés dans un système capable de traiter des sources réelles.

Le deuxième apport concerne l'évaluation. Les métriques classiques comme ROUGE, BLEU et METEOR-lite ont été complétées par des métriques de comportement et des scores proxy composites. Les dimensions de cohérence, exactitude, clarté, pertinence, efficacité, fidélité à la source et complétude permettent d'analyser plus finement les sorties des modèles. Cette approche ne remplace pas une évaluation humaine, mais elle évite de tirer des conclusions uniquement à partir d'un score lexical.

Le troisième apport est architectural. L'application sépare la génération des résumés du moment de la requête utilisateur. Les articles sont collectés et résumés en arrière-plan, puis les résultats sont stockés dans SQLite. Cette décision rend le système plus utilisable, car l'utilisateur consulte des résumés déjà préparés au lieu d'attendre l'exécution d'un modèle à chaque appel API. La présence de filtres par langue, sujet, pays, région, source, mot-clé et modèle rend aussi le prototype plus proche d'un outil exploitable.

Enfin, le projet prend en compte des contraintes pratiques et éthiques. Les liens vers les articles originaux sont conservés, les modèles multilingues sont contrôlés selon la langue choisie, et des mécanismes de nettoyage, de post-traitement et de résumé extractif de secours limitent les sorties de mauvaise qualité. Le résumé est donc présenté comme une aide à la lecture rapide, non comme un remplacement définitif de l'article source.

7.4 Limites du projet

Malgré ces résultats, plusieurs limites doivent être soulignées. La première concerne l'évaluation automatique. Les scores proxy construits dans le projet sont utiles pour comparer les modèles dans les mêmes conditions, mais ils restent heuristiques. Ils ne prouvent pas à eux seuls la qualité humaine d'un résumé, ni sa véracité factuelle dans le monde réel. Une évaluation humaine reste nécessaire pour mesurer plus directement la cohérence, la fluidité, la pertinence et la confiance perçue par les utilisateurs.

La deuxième limite concerne la fidélité factuelle. Le projet mesure la proximité au texte source avec des signaux comme `source_coverage`, `fragment_coverage` et `quality_factuality`. Ces mesures peuvent indiquer si le résumé reste proche de l'article, mais elles ne constituent pas un système complet de vérification des faits. Un résumé peut être lexicalement proche de la source tout en supprimant un contexte important, ou reformuler une information de manière ambiguë.

La troisième limite vient de la différence entre XL-Sum et les flux RSS réels. XL-Sum fournit des articles et des résumés de référence propres, alors que les sources d'actualités en ligne contiennent souvent du bruit, des structures HTML variables, des titres répétés, des extraits incomplets ou des contenus non journalistiques. L'application intègre des mécanismes de nettoyage et de filtrage, mais la qualité de l'extraction dépend encore fortement des sites sources.

La quatrième limite est linguistique. L'évaluation finale couvre 11 langues, alors que l'application en propose 15. Les langues allemand, italien, néerlandais et roumain restent disponibles dans le flux applicatif, mais elles ne disposent pas ici de résultats expérimentaux comparables. De plus, les performances varient selon les langues, notamment en fonction de la taille des données disponibles, de la tokenisation et des spécificités de chaque système d'écriture.

Enfin, la latence mesurée dépend de l'environnement matériel, de la taille des batchs, des réglages de génération et de l'état de la machine au moment de l'évaluation. Les conclusions sur la vitesse sont donc valables pour la configuration expérimentale utilisée,

mais elles doivent être revalidées avant un déploiement sur une infrastructure différente.

7.5 Perspectives d'amélioration

Une première perspective consiste à ajouter une évaluation humaine structurée. Des annotateurs pourraient comparer les résumés selon plusieurs critères: fidélité à la source, couverture de l'information, clarté, absence de répétition et utilité pour une lecture rapide. Cette évaluation permettrait de vérifier si les scores proxy sont bien alignés avec le jugement humain et d'ajuster leurs poids si nécessaire.

Une deuxième perspective concerne l'évaluation factuelle. Le système pourrait intégrer des métriques plus spécialisées de cohérence factuelle ou des méthodes basées sur questions-réponses et inférence textuelle. L'objectif serait de détecter plus directement les contradictions, les entités incorrectes, les chiffres modifiés ou les informations absentes de la source. Cette évolution serait particulièrement importante pour les nouvelles politiques, économiques, médicales ou scientifiques.

Une troisième piste est l'amélioration des modèles. Les deux modèles mBART pourraient être réentraînés avec une validation plus fine par langue, des jeux de données supplémentaires, des stratégies d'adaptation légère ou une distillation vers des modèles plus petits. Une approche intéressante serait de conserver la qualité du modèle le plus fort tout en réduisant le coût de génération, afin de mieux servir l'application en temps réel.

Une quatrième perspective est la construction d'un jeu de test local pour les langues non couvertes dans l'évaluation XL-Sum finale. Un ensemble d'articles et de résumés de référence pour l'allemand, l'italien, le néerlandais et le roumain permettrait de valider quantitativement les 15 langues de l'application. Ce jeu de test pourrait aussi inclure des exemples directement issus des sources RSS utilisées par le système, afin de rapprocher l'évaluation du contexte applicatif réel.

Une cinquième perspective concerne l'application web. Le système pourrait proposer une comparaison visuelle entre plusieurs résumés du même article, un indicateur de confiance, une alerte lorsque l'extraction du texte est faible, ou une option permettant à l'utilisateur

de signaler un résumé incorrect. Les retours utilisateurs pourraient ensuite alimenter une évaluation continue et aider à identifier les sources ou les langues qui posent le plus de problèmes.

Enfin, l’architecture pourrait être renforcée pour un usage plus large. L’utilisation d’une base plus robuste que SQLite, l’ajout d’une file de tâches dédiée, la mise en cache plus fine des modèles, la surveillance des erreurs d’ingestion et la gestion de quotas par source permettraient de rendre le système plus fiable dans un contexte de production.

7.6 Conclusion finale

En conclusion, ce projet montre qu’un système de résumé automatique d’actualités multilingues doit être pensé comme un ensemble complet, et non comme un simple appel à un modèle de langage. La qualité finale dépend à la fois des données, de l’entraînement, des métriques d’évaluation, de la fidélité au texte source, du temps de génération et de l’intégration logicielle.

Les résultats obtenus montrent que le modèle mT5 prêt à l’emploi reste une référence forte pour la similarité avec les résumés humains, mais que les modèles mBART entraînés dans le cadre du projet offrent un compromis applicatif pertinent, en particulier pour la vitesse et l’utilisation dans un flux d’actualités. Le modèle `mbart50_xlsum` apparaît comme le choix le plus prudent pour une utilisation par défaut, tandis que `mbart-xlsum-2` constitue une alternative plus rapide et plus abstractive.

Le projet atteint ainsi son objectif principal: proposer une chaîne de bout en bout qui relie l’entraînement et l’évaluation de modèles de résumé multilingue à une application web fonctionnelle. Les limites identifiées ouvrent des pistes claires pour la suite, notamment l’évaluation humaine, le contrôle factuel, l’extension linguistique et le passage vers une architecture plus robuste. Ces perspectives montrent que le système développé constitue une base exploitable pour de futurs travaux sur l’accès rapide, multilingue et fiable à l’information d’actualité.

Bibliographie

- Banerjee, S. & Lavie, A. (2005). METEOR: An automatic metric for MT evaluation with improved correlation with human judgments. In *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization* (pp. 65–72).
- Fabbri, A. R., Kryscinski, W., McCann, B., Xiong, C., Socher, R., & Radev, D. (2021). SummEval: Re-evaluating summarization evaluation. *Transactions of the Association for Computational Linguistics*, 9, 391–409.
- Fabbri, A. R., Li, I., She, T., Li, S., & Radev, D. R. (2019). Multi-news: A large-scale multi-document summarization dataset and abstractive hierarchical model. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics* (pp. 1074–1084).
- Grusky, M., Naaman, M., & Artzi, Y. (2018). NEWSROOM: A dataset of 1.3 million summaries with diverse extractive strategies. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics* (pp. 708–719).
- Hasan, T., Bhattacharjee, A., Islam, M. S., Mubasshir, K., Li, Y.-F., Kang, Y.-B., Rahman, M. S., & Shahriyar, R. (2021). XL-Sum: Large-scale multilingual abstractive summarization for 44 languages. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021* (pp. 4693–4703).
- Hermann, K. M., Kocisky, T., Grefenstette, E., Espeholt, L., Kay, W., Suleyman, M., & Blunsom, P. (2015). Teaching machines to read and comprehend. In *Advances in Neural Information Processing Systems*.
- Kryscinski, W., McCann, B., Xiong, C., & Socher, R. (2020). Evaluating the factual consistency of abstractive text summarization. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing* (pp. 9332–9346).

- Laban, P., Schnabel, T., Bennett, P. N., & Hearst, M. A. (2022). SummaC: Re-visiting NLI-based models for inconsistency detection in summarization. *Transactions of the Association for Computational Linguistics*, 10, 163–177.
- Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., & Zettlemoyer, L. (2020). BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, (pp. 7871–7880).
- Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out* (pp. 74–81).
- Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., & Zettlemoyer, L. (2020). Multilingual denoising pre-training for neural machine translation. *Transactions of the Association for Computational Linguistics*, 8, 726–742.
- Maynez, J., Narayan, S., Bohnet, B., & McDonald, R. (2020). On faithfulness and factuality in abstractive summarization. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 1906–1919).
- McKeown, K., Barzilay, R., Evans, D., Hatzivassiloglou, V., Klavans, J. L., Nenkova, A., Sable, C., Schiffman, B., & Sigelman, S. (2002). Tracking and summarizing news on a daily basis with columbia’s newsblaster. In *Proceedings of the Human Language Technology Conference*.
- Miller, J. K. & Tang, W. (2025). Evaluating LLM metrics through real-world capabilities.
- Nallapati, R., Zhou, B., dos Santos, C., Gulcehre, C., & Xiang, B. (2016). Abstractive text summarization using sequence-to-sequence rnns and beyond. In *Proceedings of The 20th SIGNLL Conference on Computational Natural Language Learning* (pp. 280–290).
- Narayan, S., Cohen, S. B., & Lapata, M. (2018). Don’t give me the details, just the summary! topic-aware convolutional neural networks for extreme summarization. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing* (pp. 1797–1807).

- Newman, N., Fletcher, R., Robertson, C. T., Ross Arguedas, A., & Nielsen, R. K. (2024). *Digital News Report 2024*. Technical report, Reuters Institute for the Study of Journalism, University of Oxford.
- Newman, N., Fletcher, R., Robertson, C. T., Ross Arguedas, A., & Nielsen, R. K. (2025). *Digital News Report 2025*. Technical report, Reuters Institute for the Study of Journalism, University of Oxford.
- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics* (pp. 311–318).
- Radev, D. R., Allison, T., Blair-Goldensohn, S., Blitzer, J., Celebi, A., Dimitrov, S., Drabek, E., Hakim, A., Lam, W., Liu, D., Otterbacher, J., Qi, H., Saggion, H., Teufel, S., Topper, M., Winkel, A., & Zhang, Z. (2004). MEAD: A platform for multidocument multilingual text summarization. In *Proceedings of the Fourth International Conference on Language Resources and Evaluation*.
- Scialom, T., Dray, P.-A., Lamprier, S., Piwowski, B., & Staiano, J. (2020). MLSUM: The multilingual summarization corpus. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing* (pp. 8051–8067).
- Scialom, T., Dray, P.-A., Lamprier, S., Piwowski, B., Staiano, J., Wang, A., & Gallinari, P. (2021). QuestEval: Summarization asks for fact-based evaluation. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing* (pp. 6594–6604).
- See, A., Liu, P. J., & Manning, C. D. (2017). Get to the point: Summarization with pointer-generator networks. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics* (pp. 1073–1083).
- Tang, Y., Tran, C., Li, X., Chen, P.-J., Goyal, N., Chaudhary, V., Gu, J., & Fan, A. (2020). Multilingual translation with extensible multilingual pretraining and finetuning. In *arXiv preprint arXiv:2008.00401*.

Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., & Raf-fel, C. (2021). mT5: A massively multilingual pre-trained text-to-text transformer. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics* (pp. 483–498).

Zhang, J., Zhao, Y., Saleh, M., & Liu, P. J. (2020). PEGASUS: Pre-training with extracted gap-sentences for abstractive summarization. In *Proceedings of the 37th International Conference on Machine Learning* (pp. 11328–11339).

ANNEXES

Diagnostic du corpus




Figure – Ratio de compression moyen par langue et par split

Scores par langue et par modele

Tableau – Metriques standard par langue et par modele

Langue	Modele	R-1	R-2	R-L	BLEU	METEOR
en	mT5	0.354	0.139	0.284	0.097	0.296
	mBART50	0.349	0.133	0.277	0.096	0.302
	mBART-2	0.345	0.129	0.272	0.093	0.299
tr	mT5	0.259	0.120	0.238	0.081	0.214
	mBART50	0.229	0.098	0.207	0.070	0.199
	mBART-2	0.233	0.101	0.209	0.073	0.203
fr	mT5	0.328	0.149	0.267	0.102	0.272
	mBART50	0.312	0.134	0.250	0.095	0.268
	mBART-2	0.312	0.133	0.250	0.096	0.268
es	mT5	0.313	0.115	0.237	0.074	0.248
	mBART50	0.303	0.101	0.225	0.068	0.252
	mBART-2	0.301	0.102	0.225	0.070	0.250
ru	mT5	0.252	0.104	0.212	0.068	0.199
	mBART50	0.240	0.093	0.200	0.063	0.193
	mBART-2	0.243	0.094	0.202	0.064	0.197
ar	mT5	0.287	0.126	0.248	0.080	0.236
	mBART50	0.267	0.110	0.228	0.073	0.225
	mBART-2	0.266	0.110	0.226	0.074	0.226
hi	mT5	0.568	0.307	0.420	0.217	0.504
	mBART50	0.568	0.290	0.405	0.212	0.530
	mBART-2	0.569	0.294	0.409	0.216	0.529
zh	mT5	0.441	0.287	0.367	0.193	0.399
	mBART50	0.388	0.234	0.311	0.155	0.365
	mBART-2	0.389	0.234	0.313	0.156	0.361
ja	mT5	0.529	0.348	0.406	0.238	0.463
	mBART50	0.500	0.307	0.367	0.213	0.444
	mBART-2	0.508	0.312	0.369	0.223	0.456
ko	mT5	0.466	0.284	0.382	0.204	0.420
	mBART50	0.430	0.249	0.343	0.182	0.404
	mBART-2	0.435	0.251	0.344	0.189	0.418
vi	mT5	0.320	0.154	0.249	0.086	0.264
	mBART50	0.328	0.157	0.251	0.095	0.290
	mBART-2	0.331	0.159	0.253	0.096	0.291

Tableau – Metriques de mesure et de comportement par langue et par modele

Langue	Modele	Lat.	Lat./1k	Comp.	Cov. src.	Rappel src.	Nouv. 2g	Rep. 3g
en	mT5	0.175	0.557	25.213	0.818	0.072	0.628	0.000
	mBART50	0.135	0.429	22.449	0.797	0.075	0.653	0.000
	mBART-2	0.135	0.429	22.386	0.789	0.075	0.661	0.000
tr	mT5	0.258	1.008	22.992	0.702	0.056	0.620	0.000
	mBART50	0.214	0.833	18.379	0.686	0.065	0.632	0.000
	mBART-2	0.204	0.799	18.649	0.643	0.060	0.680	0.000
fr	mT5	0.241	1.002	20.757	0.855	0.099	0.441	0.000
	mBART50	0.182	0.760	18.207	0.873	0.111	0.386	0.000
	mBART-2	0.179	0.743	17.910	0.826	0.106	0.479	0.000
es	mT5	0.235	0.463	42.974	0.839	0.054	0.485	0.000
	mBART50	0.173	0.338	34.350	0.838	0.062	0.480	0.001
	mBART-2	0.175	0.342	34.900	0.802	0.059	0.532	0.000
ru	mT5	0.269	0.862	28.287	0.723	0.052	0.615	0.000
	mBART50	0.192	0.617	25.502	0.714	0.055	0.622	0.000
	mBART-2	0.192	0.616	24.764	0.674	0.053	0.670	0.000
ar	mT5	0.272	0.942	22.308	0.749	0.062	0.584	0.000
	mBART50	0.179	0.618	19.860	0.743	0.067	0.575	0.000
	mBART-2	0.179	0.618	19.500	0.694	0.063	0.624	0.000
hi	mT5	0.287	0.469	23.874	0.962	0.182	0.178	0.002
	mBART50	0.181	0.296	20.046	0.958	0.195	0.181	0.013
	mBART-2	0.179	0.292	20.307	0.952	0.193	0.200	0.013
zh	mT5	0.214	0.341	25.909	0.920	0.106	0.293	0.003
	mBART50	0.191	0.304	22.183	0.936	0.121	0.236	0.008
	mBART-2	0.177	0.282	23.287	0.917	0.113	0.287	0.007
ja	mT5	0.277	0.245	26.603	0.939	0.139	0.283	0.007
	mBART50	0.258	0.227	24.491	0.953	0.147	0.246	0.010
	mBART-2	0.219	0.194	23.484	0.929	0.146	0.308	0.010
ko	mT5	0.235	0.284	33.885	0.956	0.123	0.271	0.005
	mBART50	0.193	0.232	29.121	0.950	0.135	0.262	0.011
	mBART-2	0.189	0.229	27.395	0.935	0.139	0.326	0.008
vi	mT5	0.344	0.707	25.680	0.879	0.092	0.397	0.000
	mBART50	0.212	0.436	21.192	0.881	0.104	0.378	0.000
	mBART-2	0.197	0.406	21.525	0.863	0.101	0.416	0.000

Tableau – Metriques composites par langue et par modele

Langue	Modele	Coh.	Acc.	Clarte	Rel.	Eff.	Cap.	Fact.	Compl.
en	mT5	0.997	0.403	0.730	0.255	0.731	0.623	0.821	0.465
	mBART50	0.995	0.397	0.725	0.263	0.749	0.626	0.802	0.477
	mBART-2	0.995	0.392	0.722	0.261	0.747	0.623	0.795	0.476
tr	mT5	0.995	0.335	0.994	0.185	0.630	0.628	0.703	0.378
	mBART50	0.983	0.317	0.987	0.181	0.625	0.619	0.689	0.367
	mBART-2	0.984	0.306	0.988	0.181	0.631	0.618	0.645	0.375
fr	mT5	0.997	0.406	0.991	0.241	0.595	0.646	0.857	0.424
	mBART50	0.990	0.405	0.978	0.246	0.612	0.646	0.876	0.423
	mBART-2	0.992	0.391	0.980	0.245	0.614	0.644	0.831	0.430
es	mT5	0.988	0.382	0.978	0.215	0.798	0.672	0.845	0.397
	mBART50	0.972	0.379	0.952	0.225	0.822	0.670	0.847	0.408
	mBART-2	0.973	0.368	0.955	0.222	0.821	0.668	0.811	0.408
ru	mT5	0.991	0.329	0.995	0.174	0.687	0.635	0.727	0.363
	mBART50	0.989	0.320	0.991	0.172	0.720	0.638	0.718	0.366
	mBART-2	0.986	0.310	0.991	0.176	0.716	0.636	0.678	0.372
ar	mT5	0.998	0.356	0.995	0.201	0.641	0.638	0.751	0.397
	mBART50	0.994	0.346	0.984	0.197	0.681	0.640	0.747	0.398
	mBART-2	0.994	0.331	0.985	0.197	0.678	0.637	0.697	0.401
hi	mT5	0.901	0.555	0.668	0.415	0.733	0.654	0.967	0.571
	mBART50	0.868	0.555	0.613	0.441	0.762	0.648	0.964	0.599
	mBART-2	0.870	0.555	0.621	0.439	0.765	0.650	0.959	0.599
zh	mT5	0.986	0.500	0.985	0.315	0.781	0.713	0.923	0.496
	mBART50	0.964	0.475	0.958	0.301	0.772	0.694	0.938	0.477
	mBART-2	0.971	0.469	0.969	0.295	0.783	0.698	0.919	0.476
ja	mT5	0.905	0.540	0.844	0.365	0.834	0.698	0.943	0.525
	mBART50	0.903	0.525	0.817	0.358	0.833	0.687	0.956	0.519
	mBART-2	0.861	0.523	0.818	0.366	0.842	0.682	0.934	0.536
ko	mT5	0.987	0.521	0.977	0.340	0.842	0.733	0.957	0.519
	mBART50	0.973	0.502	0.959	0.338	0.847	0.724	0.952	0.505
	mBART-2	0.969	0.502	0.950	0.350	0.843	0.723	0.939	0.521
vi	mT5	0.981	0.403	0.940	0.223	0.715	0.652	0.880	0.403
	mBART50	0.954	0.413	0.854	0.248	0.753	0.644	0.884	0.439
	mBART-2	0.957	0.408	0.866	0.247	0.762	0.648	0.866	0.441

Extraits de code essentiels

Assemblage des services

```
class AppContainer:
    def __init__(self):
        self.catalog_service = CatalogService()
        self.news_service = NewsService()
        self.article_service = ArticleService()
        self.summarization_service = SummarizationService()
        self.storage_service = StorageService()
        self.ingestion_service = IngestionService(
            catalog_service=self.catalog_service,
            news_service=self.news_service,
            article_service=self.article_service,
            summarization_service=self.summarization_service,
            storage_service=self.storage_service,
        )
        self.ingest_scheduler_service = IngestSchedulerService(self.ingestion_service)
```

Ingestion en arriere-plan

```
for language_key in config["languages"]:
    entries = self._round_robin_entries_by_source(
        self.news_service.gather(
            limit_per_source=config["fetch_limit_per_source"],
            language_key=language_key,
            selected_sources=config["selected_sources"],
            topic_key=config["topic"],
            country_key=config["country"],
            region_key=config["region"],
        )
    )

    for entry in entries:
        article_text = self.article_service.fetch_and_clean(entry, language_key)
        if not article_text:
            continue
        payload = self._build_item_payload(entry, language_key, article_text)
        news_item_id, inserted = self.storage_service.upsert_news_item(payload)
        for model_key in config["model_keys"]:
            summary = self.summarization_service.summarize_article(
                text=article_text,
                title=entry["title"],
                model_key=model_key,
                language_key=language_key,
                article_key=entry.get("link", ""),
```

```

    )
    self.storage_service.upsert_summary(
        news_item_id, model_key, language_key, summary
    )

```

Schema de stockage

```

CREATE TABLE IF NOT EXISTS news_items (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    link TEXT NOT NULL UNIQUE,
    source_key TEXT NOT NULL,
    source_name TEXT NOT NULL,
    language_key TEXT NOT NULL,
    title TEXT NOT NULL,
    article_text TEXT NOT NULL,
    fetched_at TEXT NOT NULL,
    updated_at TEXT NOT NULL
);

CREATE TABLE IF NOT EXISTS news_summaries (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    news_item_id INTEGER NOT NULL,
    model_key TEXT NOT NULL,
    language_key TEXT NOT NULL,
    summary TEXT NOT NULL,
    UNIQUE(news_item_id, model_key, language_key),
    FOREIGN KEY(news_item_id) REFERENCES news_items(id) ON DELETE CASCADE
);

```